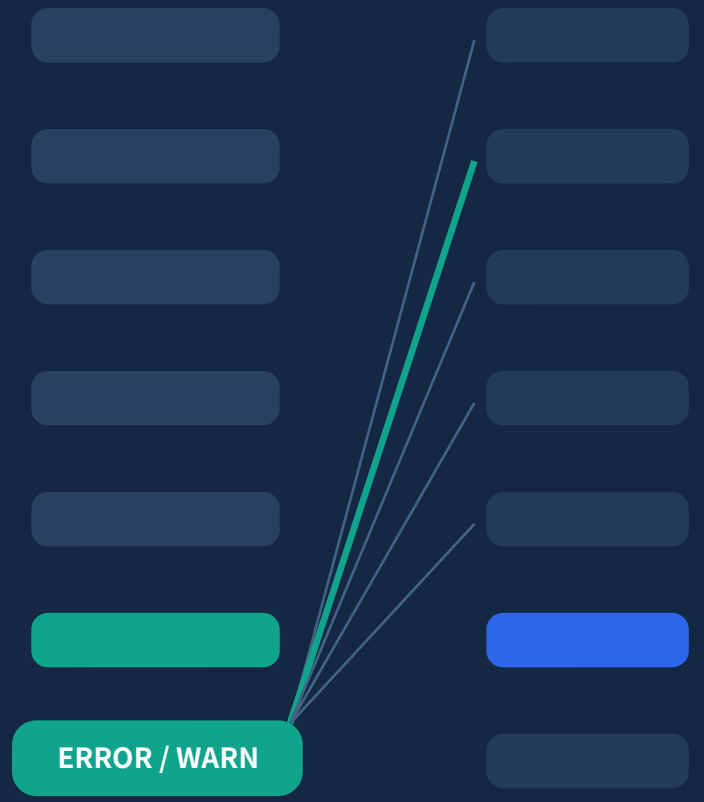
LOGPRESS

전체 실험 개요

WARN/ERROR Query Anchor 기반 Evidence Line Ranking 검증



연구 질문 → 실험 설계 → 평가 · 판정 → 후속 압축

RESEARCH OVERVIEW / NOV 2026

왜 이 실험이 필요한가

긴 로그를 압축할 때 정말 남겨야 할 원인 · 증거 라인을 보존하려면 , 먼저 “중요도 신호”를 검증해야 한다 .

01

긴 시스템 로그

시간순 로그가 길어질수록
입력 문맥이 커진다 .

→

02

KV Cache 비용 증가

입력 토큰 증가로 메모리 ·
추론 비용이 커진다 .

→

03

Evidence 유실 위험

무조건 압축하면 근본 원인을
설명하는 라인이 사라질 수 있다 .

핵심 접근

**Token 만이 아니라 Log Line(이벤트) 단위로 중요도를 평가하고 ,
그 점수가 실제 Evidence 와 맞는지 확인한다 .**

핵심 가설 : Attention 으로 이전 Evidence 를 찾을 수 있을까 ?

이번 단계의 목표는 “압축 성능” 이 아니라 WARN/ERROR Anchor 의 Evidence Ranking 유효성을 확인하는 것이다 .

RQ1 · PRIMARY QUESTION

WARN/ERROR 로그를 Query Anchor 로 사용하면 ,
실제 원인 · 증거 로그를 다른 전략보다
더 높은 순위에 배치할 수 있는가 ?

QUERY

ERROR / WARN line

장애 · 경고를 나타내는 로그

CANDIDATE

Anchor 이전의 log lines

인과적으로 참조 가능한 과거 라인

GROUND TRUTH

Root-cause / Evidence IDs

사전에 지정한 실제 정답 라인

v7 에서 Anchor 로 , 질문의 방향이 바뀌었다

기존 접근을 “실패했다”고 단정하는 것이 아니라 , 실제 RCA Evidence 보존 목표에 더 직접적인 질문으로 좁힌 것이다 .

PREVIOUS · v7

Alert / Normal 신호 구별

후속 로그 Q → Alert / Normal K

“Alert 가 후속 로그에서
더 큰 Attention 을 받는가 ?”

CURRENT · ANCHOR

이전 Evidence 검색

WARN / ERROR Q → 이전 Evidence K

**“장애 로그가 이전 원인 · 증거를
상위에 놓는가 ?”**

연구 설계 변경의 핵심 : “ 이상 상태의 차이” 관찰 → “실제 정답 Evidence 순위” 검증

실험 파이프라인 : 로그에서 정답 순위까지

모델 Attention 을 계산하는 단계와 , 그 점수가 실제 Evidence 를 찾는지 평가하는 단계를 분리한다 .

01
로그 · 정답 준비
Incident / line ID / Evidence annotation

›

02
토큰 매핑
Tokenizer / span→line

›

03
Attention 추출
Qwen2.5-3B-Instruct [L,H,Tq,Tk]

›

04
Line Attention
Key SUM · Query MEAN [L,H,Lq,Lk]

›

05
Anchor Ranking
WARN/ERROR Query row 과거 candidate 정렬

›

06
Ground Truth 평가
MAP · Recall@K · Baseline 비교

구현 · 테스트 진행 : Token Mapping → Attention → Line Aggregation

현재 중점 : Ranking 평가 설계

Attention 을 어떻게 Line 점수로 바꾸나 ?

구현된 Token → Line Aggregation 규칙을 유지하며 , 평가할 Layer·Head 결합 방법은 사전 고정한다 .

STEP 1

Query 토큰 하나가 Key Line 에 준 Attention 을 합산

같은 Key line 에 속한 토큰 Attention → SUM

STEP 2

Query Line 에 속한 토큰들에 대해 평균

같은 Query line 에 속한 토큰 Attention → MEAN

STEP 3

Head / Layer 정보는 우선 보존

[Layer, Head, Query Line, Key Line]

평가 점수

$$\text{Score}(a, k) = A_{\text{line}}(a \rightarrow k)$$

a: Anchor · k: 과거 Candidate

중요 : Attention 이 높다는 사실만으로 Root Cause 라고 단정하지 않는다 . 반드시 정답 ID 와 비교한다 .

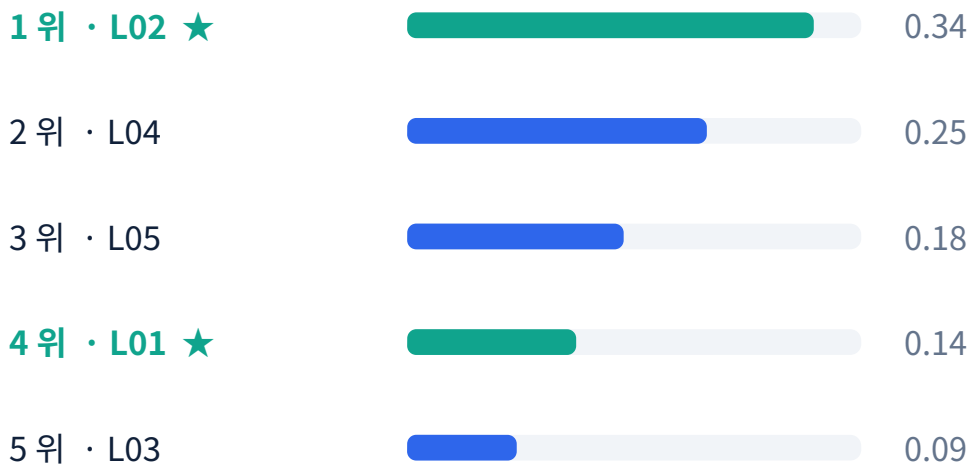
한 번의 실험은 이렇게 진행된다

ERROR Anchor 이전의 Candidate 를 Attention 점수로 정렬한 뒤 , 정답 Evidence 가 얼마나 앞에 나타나는지 본다 .

원본 로그 / 시간순

L01	INFO	DB pool utilization 95%	GT
L02	INFO	connection retry initiated	GT
L03	INFO	worker heartbeat	
L04	WARN	request latency rising	
L05	INFO	background sync started	
L06	ERROR	request timed out	Q

Anchor 가 생성한 후보 Ranking



GT 순위 : 1 위 · 4 위 → AP = (1 + 2/4) / 2 = 0.75

설명용 가상 데이터 · 점수이며 실제 모델 측정 결과가 아님

무엇과 비교해야 Anchor 의 가치를 말할 수 있나 ?

같은 Candidate·Ground Truth 를 사용해야 순위 차이를 Query 전략의 차이로 해석할 수 있다 .

PROPOSED

WARN / ERROR

해당 장애 · 경고 한 줄의 Attention 으로 Ranking

제안 방법

PRIMARY CONTROL

Position INFO

가능한 동일 위치 · 공통 Prefix 의 INFO Query

Query 신호 비교

PRIMARY CONTROL

Recency

Anchor 와 가까운 로그를 우선 순위로 배치

근접성 효과 통제

STRATEGY TEST

All-Query

여러 유효 Query 의 Attention 을 집계

한 줄 집중의 이점

SANITY CHECK

Random

동일 후보를 무작위로 정렬한 기대 수준

우연 성능 확인

공통 원칙 · 동일한 과거 후보 / 정답 ID · Causal 접근 조건 충족 · 사전 고정된 Head·Layer 집계

평가의 중심은 “ Evidence Ranking 품질”

지표는 서로 다른 질문을 측정한다 . 주 지표는 MAP 이며 , Top-K 보존 효과는 Recall@K 로 함께 본다 .

PRIMARY

MAP · Mean Average Precision

정답 Evidence 가 여러 개일 때 , 각각 얼마나 높은 순위에 나타나는지 평가

$$AP = (P@r_1 + P@r_2 + \ldots + P@r^R) / R$$

예) 두 Evidence 가 1 위와 4 위 → AP = (1.00 + 0.50) / 2 = 0.75

※ 정답 한 줄이면 AP = RR, 따라서 MAP 과 MRR 이 동일

Recall@5 / Recall@10

상위 K 개 안에 들어온 정답 비율
실제 Line 보존 예산을 해석

진단용 지표

MRR: 첫 Evidence 의 발견 순위
AUC / PRS: 정답 · 비정답 구별
Precision@K: 상위 K 내 정답 밀도

좋은 점수가 나와도 놓치면 안 되는 통제

Evidence Ranking 실험에서는 위치 · 정답 라벨 · 샘플 독립성에 따른 착시를 막는 것이 중요하다 .

01 정답 라벨 품질

Anomaly 와 실제 Root Cause 를
근거 없이 동일 정답으로 합치지 않기

02 후보 ·Causal 공정성

Anchor 이전 후보만 사용하고
INFO 와 공통 Prefix 로 비교

03 거리 · 위치 편향

Anchor-Evidence 거리 분석 및
Recency 기준과 직접 비교

04 사후 최적화 방지

결과를 보고 best head 를 고르지 않고
집계 규칙 · 동점 기준을 사전 고정

추가 주의 : 여러 Anchor 가 같은 Incident 에 속한다면 독립 관측치처럼 취급하지 않고 Incident 단위로 통계를 계산

어떤 결과면 다음 단계로 넘어갈까 ?

절대 MAP 점수보다 동일 후보에서의 ΔMAP 와 통계적 불확실성 , 거리별 일관성을 함께 판단한 .

GO

① INFO 와 Recency 대비
두 ΔMAP 모두 양수
② 두 비교의 Holm 조정
p-value < 0.05
③ Recall@K 방향 등
보조 지표도 점검

CONDITIONAL

일부 비교 · 데이터에서만
우위가 확인될 때

특정 조건의 유효성 또는
추가 데이터로 재검증

NO-GO / HOLD

사전 지정한 두 핵심
비교의 GO 조건 미충족

무효 증명은 아니며
가설 수정 · 검증 보류

통계 : Incident 단위 Paired Bootstrap 95% CI · Paired Permutation · Holm 보정 (Primary 2 개)

지금의 위치와 다음 실험

이번 검증을 통과한 뒤에야 Attention 기반 Line Selection 을 실제 KV Cache 압축 정책으로 사용할 근거가 생긴다 .

01

기반 구현

Token Mapping
Token Attention
Line Aggregation

기능 테스트 완료

02

현재 실험

Anchor Score
GT Evidence Ranking
Baseline / MAP 비교

평가 코드 · 데이터 검증

03

실증 분석

다수 Incident
CI / p-value
거리별 · 종류별 분석

다음 실행 단계

04

후속 연구

Top-K Line Retention
Layer-wise KV 압축
RCA 성능 · 비용 평가

가설 통과 후

한 문장 정리 | “WARN/ERROR Query 가 실제 이전 Evidence 를 더 잘 찾는가 ?” 부터 먼저 검증한다 .