

이 문서의 범위 ROC와 AUC가 정확히 무엇이며 킬스위치의 어느 대상에 대응하는가 — 개념 정의에 한정한다. 임계값(AUC 0.65 · cause 40 · n\_hard 300)의 정당화와 문헌 근거는 「판정식프리즈\_임계값감사」 및 「검정력분석\_근거」를, 세 관문에서의 검정 배치는 「killswitch\_freeze\_v2.3」을 참조하라.

## 1. ROC와 AUC란 무엇인가

### 1.1 출발점 — 컷오프를 어디에 둘 것인가

신호(rarity + 위치)는 각 단위에 점수를 매긴다. 점수가 높으면 원인일 가능성이 크다는 뜻이다. 그런데 실제로 판정하려면 선을 그어야 한다 — “점수 2.0을 넘으면 원인으로 본다” 같은 식으로. 문제는 그 선을 어디에 굿느냐에 따라 결과가 완전히 달라진다는 점이다.

- 컷오프를 낮추면 → 진짜 원인은 거의 다 잡지만, 평범한 라인도 대량으로 떨어 온다
- 컷오프를 높이면 → 오탐은 줄지만, 진짜 원인을 놓친다

따라서 “컷오프 2.0에서 정확도 80%” 같은 수치는 신호 자체의 능력이 아니라 **컷오프를 잘 골랐다는 사실**을 반영할 수 있다. ROC는 이 자의성을 제거하기 위해 존재한다.

### 1.2 두 개의 비율 — TPR과 FPR

컷오프를 하나 정하면 두 숫자가 나온다.

- TPR (재현율, 민감도)** = 진짜 원인 중 내가 잡아낸 비율
- FPR (오탐률, 1-특이도)** = 평범한 라인 중 내가 잘못 잡은 비율

컷오프 하나 = (FPR, TPR) 좌표 하나다.

### 1.3 컷오프를 전부 훑으면 곡선이 된다

컷오프를  $-\infty$ 에서  $+\infty$ 까지 이동시키며 얻은 점들을 이으면 **ROC 곡선**(Receiver Operating Characteristic)이 된다. 특정 컷오프에 의존하지 않고 **이 신호가 낼 수 있는 성능 전체**를 한 장에 담은 것이다.

### 1.4 AUC — 곡선 아래 면적

곡선이 왼쪽 위로 부풀수록 좋은 신호다(같은 오탐률에서 더 많이 잡아낸다). 그 부푼 정도를 숫자 하나로 요약한 것이 **AUC**(Area Under the Curve)다.

그림 1. AUC 0.5는 대각선과 겹쳐 무변별, 0.65는 우리 임계값, 0.90은 강한 신호. 음영이 AUC.

| AUC  | 의미                                      |
|------|-----------------------------------------|
| 0.5  | 곡선이 대각선과 일치. 동전던지기과 같음 — 신호 무력          |
| 0.65 | <b>우리 임계값</b> . 분포가 대부분 겹치되 살짝 밀려 있는 상태 |
| 0.9+ | 거의 완전 분리. 원인 라인이 대체로 평범한 라인보다 높은 점수     |
| 1.0  | 완전 분리(현실 로그에서는 라벨 누수를 의심해야 함)           |

### 1.5 AUC의 진짜 의미 — 확률 해석

가장 중요한 한 문장 **AUC = 원인 단위 하나와 평범한 단위 하나를 무작위로 뽑았을 때, 원인 쪽 점수가 더 높을 확률** 따라서 AUC 0.65는 “cause 단위와 non-cause 단위를 아무거나 하나씩 집어 비교하면 65% 확률로 cause가 더 높다”는 뜻이다. 정의에 컷오프가 전혀 등장하지 않는다 — 이것이 ROC를 쓰는 이유다.

### 1.6 Mann-Whitney U와의 동치

위 확률 정의 때문에 AUC는 Mann-Whitney U 통계량과 수학적으로 동일하다 — **AUC =  $U / (n_1 \cdot n_2)$** . 순위만 사용하므로 정규분포 가정이 필요 없고, 분포가 비대칭인 로그 데이터에 적합하다. 효과크기는 rank-biserial 상관  **$r = 2 \cdot AUC - 1$** 로 보고한다(AUC 0.65 →  $r = 0.30$  = Cohen medium 하한). 원전은 Hanley & McNeil (1982).

```
from scipy.stats import mannwhitneyu
from sklearn.metrics import roc_auc_score
```

```
U, p = mannwhitneyu(x[y==1], x[y==0], alternative='greater')
auc = roc_auc_score(y, x) # = U / (n1*n2)
r_rb = 2*auc - 1 # rank-biserial 효과크기
```

1.7 LogPress 용어 대응표

| ROC 일반 용어     | 킬스위치에서의 대응                                    |
|---------------|-----------------------------------------------|
| 점수 (score)    | rarity + 위치 결합신호                              |
| 양성 (positive) | alert 태그가 붙은 cause 단위                         |
| 음성 (negative) | alert 태그가 -인 매칭 추출 단위                         |
| 검정 단위         | (노드, 템플릿, 5분 창) 하나 = 곡선 위의 점 하나               |
| AUC ≥ 0.65    | 무작위 cause가 무작위 non-cause보다 높은 점수를 받을 확률 ≥ 65% |

본 문서는 개념 정리이므로 언제든지 갱신 가능하다. 서명·커밋 대상이 아니다.