

KILL-SWITCH

킬스위치 전체 흐름

원인 줄에 신호가 있는가 — 프로젝트 최소 조건 검증

프리즈 → 킬스위치 → 검정력 → 위치 정의

최종 목표와 전제

최종 목표

로그 압축기

압축해도 원인 줄이 살아남아 LLM 이 근본 원인을 찾게

필요 전제



전제

LLM 이 원인 줄을 알아볼 수 있어야 한다


검증 질문

원인 줄이 애초에 구별 가능한 특징을 가지고 있는가 ?

없으면 → LLM 실험 불가 · 프로젝트 접기 (NO-GO)

있으면 → 다음 단계로 (GO)

3 단계 중 첫 관문



이번 관문

원인 식별 가능성 검증 · Week 3 · 통계로만 판정 (LLM 아직 없음)

프리즈 = 조작 방지 장치

결과를 보기 전에 규칙을 다 정하고 서명 · 커밋한다

만약 나중에 정하면

- 결과 보고 유리하게 기준 변경 가능
- " 운 좋게 나온 값 " 과 구별 불가
- p- 해킹 (사후 조작)

미리 정하고 봉인하면

- 기준을 못 바꿈 → 조작 불가
- GO 든 NO-GO 든 결과를 신뢰
- = 사전등록 (pre-registration)

판정 = 가설검정 (0.5 만 피하면 된다)

H_0 귀무가설

위치는 원인과 무관

$AUC = 0.5$ (구별 못 함)

H_1 대립가설

위치는 원인과 관계있음

$AUC \neq 0.5$ (양측검정)

검정 흐름

준비

위치정의③ + 음성매칭 § 8 + 표본확정

검정

AUC 측정 = Mann-Whitney U

유의성

순열검정 5,000 회 → p 값

판정

$AUC \geq 0.65$ AND $p < 0.05 \rightarrow GO$

정답지와 답안을 따로 만든다

정답지

alert 태그로 " 누가 원인 " 확정

위치는 안 봄

답안

위치 점수로 원인 맞추기 시도

태그는 안 봄

채점

정답지 vs 위치 답안 = AUC

서로 안 보고 비교 → 순환 없음

발견

원인의 59% 가
로그 중간에 위치

태그로 정한 뒤 세어보니 그렇더라는
관측. 위치로 정한 게 아니므로 순환
아님.

위치 · 희귀도 · 결합

위치 단독

판정용

신뢰성

누수 없음
(노드 + 시간)

역할

신호 존재 판정

희귀도 단독

참고용

신뢰성

라벨 누수
(태그 파생)

역할

누수 정도 확인

결합

보고용

신뢰성

누수 섞임

역할

실제 압축기 성능

희귀도는 없애지 않고 판정에서 격리 · 위치 단독이 유일하게 누수 없는 심판

6 종이지만 사건은 수천 개

의사복제 방어

한 사건이 로그 수백 줄로 찍힘
→ 줄이 아니라 관측 단위로 셈

반박 : 6 종이면 사건도 6 개 ?

감기는 1 종류지만 감기 사건은 수천만 건
→ 같은 에러라도 다른 기계 · 다른 날 = 독립

3,077

개 노드에 분산

한 기계 쓸림 아님

210

개 날짜에 분산

하루 쓸림 아님

37%

상위 15 개 노드 합계

특정 서버 쓸림 없음

CHK_DSK(13 줄 · 단일 노드) 와 본문 없는 줄은 §5 규칙으로 제외

왜 음성만 뽑는 규칙이 필요한가

양성 (원인)

이미 정해짐 · 태그 붙은 줄 전부 사용
→ 고를 게 없음

음성 (평범한 줄)

200 만 줄 · 열린 선택지
→ 어떤 걸 고르냐가 결과를 좌우

× 아무 데서나 뽑으면

- 양성 = 03 시 , 음성 = 낮 12 시 탄 노드
- " 시간대가 다르네 " 로 맞혀버림
- 위치 · 희귀도 실력 아닌 교란

✓ § 8 매칭 (같은 노드 · ±1 시간)

- 시간 · 노드가 양쪽 같음 → 교란 상쇄
- 오직 위치 · 희귀도로만 구별
- 위치는 안 맞춤 (측정 대상)

왜 0.65 인가 · 왜 순열검정인가

$AUC \geq 0.65$

= rank-biserial $r = 0.30$

= Cohen 중간효과 하한 (등식)

임의 기준이 아니라 표준 효과크기 .
" 육안으로 알아볼 수 있는 크기 "

순열검정 5,000 회

- 라벨 섞음 = 신호 없는 가짜 상황 (H_0)
- 그때 AUC 분포를 5,000 번 만들
- 실제값이 그보다 극단적 ? $\rightarrow p$ 값

핵심 : 숫자보다 ' 결과 보기 전 미리 정함 '

GO 조건

$AUC \geq 0.65$ (크기) AND 순열검정 $p < 0.05$ (우연 아님)

AUC = 원인이 더 높을 확률

원인 하나 · 평범한 줄 하나를 뽑아, 원인 위치가 더 높을 확률

Mann-Whitney U = 이것을 일일이 세지 않고 순위 합으로 빠르게 구하는 공식

1.0

원인이 항상 이김

완벽 구별

0.5

반반

구별 못 함

0.36

원인이 앞쪽에 있음

우리 결과 ③

① ② ③ — ③ 만 신호가 산다



파일 전역

AUC

0.554

위치 = 시간
매칭하면 0.5 붕괴

탈락



관측단위 내부

AUC

0.500

템플릿이 순수하게 가름
처음부터 0.5

탈락



컨텍스트 윈도우

AUC

0.36

정상 로그 섞임
0.5 에서 벗어남

채택

③ 이 되는 조건 두 가지

1 템플릿 조건 제거

노드 + 시간으로만 묶음
→ 원인 · 정상이 같은 창에 섞임

2 정상 로그 투입

원본 200 만 줄로 창을 채움
→ 원인 위치가 드러남

둘 다 필요 · 하나만으론 안 됨

템플릿만 제거 → 0.487 (거의 변화 없음) · ① 은 둘 다 해도 시각 교란 때문에 실패

정각 격자로 자르는 이유

양성 기준으로 자르면 원인이 항상 앞에 고정 → 순환 . 양성과 무관한 정각 격자라야 진짜 신호 .

NEXT

남은 한계와 다음 단계

장애 후 쓸림

정상 로그가 원인 뒤에 몰려 위치가 밀림 (뒤 / 앞 5.5 배)

경계 걸침

정각 경계 ± 5 분에 양성 17% · 격자로는 못 막음

로그 불균형

데이터셋 고질적 한계

해결

매칭
1:1 / 1:4

양쪽 같은 조건이라 쓸림 · 걸침이 상쇄됨 .
매칭 후 값이 진짜 값 .

현재 상태

$AUC \geq 0.65$ ✓ 통과 순열검정 $p < 0.05$... 미완 (코드 예정) 4 인 서명 ... 예정