

LogPress 평가 설계 (3 층)

정보 보존 · 효율 / 비용 · 출력 충실도 — 할 일과 일정

연구 위치 LogPress 는 원인을 직접 찾는 RCA 도구가 아니라 , RCA · 로그분석 모델 앞단에서 동작하는 로그 특화 KV-cache 압축 계층이다 . ‘ 원인을 찾아준다 ’ 가 아니라 ‘ 원인을 찾는 데 필요한 정보를 더 적은 메모리로 유지시켜준다 ’ 가 핵심이다 .

세 층 한눈에

1 층 정보 보존 — 원인 evidence 를 잘 남기나 (보존율 · Hit@K · NIAH)

2 층 효율 / 비용 — 메모리 · 지연을 얼마나 줄이나 (KV memory · TTFT · throughput)

3 층 출력 충실도 — 압축본과 원본 출력이 같나 (log-prob · KL), RCA 는 조연

전제 압축 신호는 어텐션 기반 (ERROR를 캐리로, 이전 로그를 캐로 내적 → 라인 중요도 → Top-K) 에 로그 신호를 결합 . 1 층 시작 전 ‘ Observed Attention 과의 차별점 ’ 을 한 문장으로 확정해 두면 baseline 비교가 명확해진다 .

1 층 — 정보 보존 (evidence recall)

1 층

압축해도 원인 evidence 를 baseline 보다 잘 남기나

가설 LogPress 는 동일 압축률에서 원인 라인을 더 많이 보존한다 .

할 일

- 압축률 50 / 70 / 90% 스윙 → 보존율 곡선 (한 점 아니라 곡선으로).
- 판정 규칙 : 연속 보존율 (라인당 생존 토큰 비율) 을 주력으로 . any(하나라도 생존) 는 참고용 .
- 층화 3 종 : 전체 / 비 -ERROR(하드케이스) / 중간 위치 .
- key-line retention · Hit@K · NIAH 식 : 원인 라인을 needle 로 심고 압축 후 살아남아 검색되는지 .
- 비교군 : 랜덤 · StreamingLLM · H2O(도메인 무지 = 하한) / 레벨필터 (도메인 인지 = 진짜 경쟁) / 무압축 (상한).
- 핵심 지표 : $\text{marginal gain} = \text{보존율 (LogPress)} - \text{보존율 (레벨필터)}$.
- 검정 : McNemar + BH 보정 (짝진 데이터).
- Ablation(효과) : attention Top-K → + 레벨 · 희귀도 → +head-aware → +output sensitivity 를 하나씩 뺄으며 각 단계의 보존율 증가분을 측정 . 어떤 신호가 실제로 보존을 올리는지 확인 .

장비 · 데이터

어텐션 추출 압축은 랩 GPU, 보존율 채점은 CPU. / Thunderbird 주력 (표본 6,637) + Nezha 슬라이스로 방향 교차검증 (진짜 원인 라벨).

참고

RULER (needle 검색 형식) · CLP (로그 압축 평가 관례)

2 층 — 효율 / 비용 (deployability)

2 층

evidence 를 유지하면서 메모리 · 비용을 얼마나 줄이나

가설 LogPress 는 evidence 를 유지한 채 KV 메모리와 지연을 크게 낮춘다 .

할 일

- KV memory reduction: 압축률별 KV 캐시 감소량 , 같은 GPU 에서 처리 가능한 최대 컨텍스트 길이 .
- TTFT(첫 토큰까지 시간) · throughput · inference time 실측 .
- 핵심 프레이밍 : retained evidence 단위당 절감 (tokens / GPU-memory / latency saved per unit of retained evidence).
- 어텐션 추출 오버헤드 (eager forward) 도 정직하게 비용에 포함해 보고 .
- 압축률 - 품질 트레이드오프 곡선은 1 층과 공유 .
- Ablation(비용 - 효과): 1 층과 같은 신호 조합을 비용측에서 평가 . 신호를 더할수록 보존율은 오르나 비용도 오르므로 (특히 head-aware·output sensitivity), 보존율 대비 비용 트레이드오프로 값어치 있는 신호만 최종 선택 .

장비

랩 GPU 실측 (메모리 · 지연은 GPU 에서 직접 측정).

참고

CLP (압축률 · 비용) · LogEval (추론시간 · 토큰) · SnapKV (곡선 형식)

주의 압축은 메모리를 아끼는 것이 목적인데 어텐션 추출은 forward 가 필요하다 . ‘evidence 단위당 순절감’ 으로 보고해 압축 이득이 추출 비용을 상쇄함을 보여야 설득력이 선다 .

3 층 — 출력 충실도 (confidence) · RCA 조연

3 층

압축본과 원본의 모델 출력이 거의 같은가

가설 필요한 정보가 유지됐다면 압축본과 원본의 출력 분포가 거의 같다.

할 일

- full context vs compressed context 출력 분포 비교.
- 정답의 log-probability / perplexity 측정 — 정답률이 바닥이어도 ‘정답 쪽으로 기울었나’ 를 연속값으로 포착.
- KL divergence(압축본 vs 무압축 출력 분포).
- 생성 끝까지 안 해도 됨 — 정답 확률만 뽑으면 되므로 가볍다.
- RCA 는 조연 : 제약형 (K 지선다 / 라인 지목) 으로 ‘보존이 헛되지 않다’ 최소 확인 . 자유서술은 바닥효과로 제외 .

장비 · 시기

랩 GPU (모델 forward 필요) · 2 월 초 .

참고

Accuracy is Not All You Need (log-prob · KL 근거) · LongBench v2 (제약형 채택 근거)

바닥효과 대비 RCA 정답률은 프론티어도 3.9~12.5% 로 낮아 압축 차이가 안 보인다 . 3 층은 ‘정답률’ 대신 ‘정답 확률 · 분포 차이’ 를 봐서 , 정답률이 0 이어도 압축 방식 간 차이를 잡아내는 안전판이다 .

일정 (간격)

~10 월 말	1 층 파이프라인 구축 압축 (어텐션 + 로그신호) + 보존을 채점 파이프라인 , 압축률 스왑 세팅
~11 월 초 (기말 전)	1 층 완주 · ablation + 2 층 메모리 보존율 곡선 · marginal gain + 1 층 신호별 ablation 확보 + KV memory 측정 → 발표 가능 최소선 확보
12~1 월 (시험 / 방학)	2 층 실측 · ablation + 3 층 준비 TTFT · throughput · inference time 실측 , 2 층 비용 - 효과 ablation, 3 층 confidence 파이프라인 구축
2 월 초	3 층 confidence + RCA 조연 log-prob · KL 측정 , 제약형 RCA 최소 확인
2 월 말	종합 · 논문화 1 · 2 층에서 돌린 ablation 결과 종합 → 최종 신호 조합 확정 , 결과 정리 · 작성

원칙 모델 없이 되는 측 (1 층 채점) 을 먼저 확보해 11 월 발표선을 잡고 , GPU 가 필요한 실측 (2 · 3 층) 은 랩 GPU 로 이어간다 . 1 층까지만 완주해도 발표는 성립한다 .