

LogPress 평가설계 근거 부속서

어텐션 주력 고정 기준 · 검정 방법 · 평가 대상 · baseline 정당성 근거대장
슬림 기획서(평가설계) 부속 · 2026 · 전거: 평가방법_정당성 · 검정력_분석 · killswitch_freeze_v3 · 평가지표(v7) · description

전제

본 문서는 **어텐션을 주력 압축기로 고정**한 기준으로 정리한다. 어텐션 고정이 바뀌는 것은 1·2층의 "우리 압축기"가 어텐션 기반이 된다는 점뿐이며, **검정 방법 · 평가 대상 · baseline 조합 · 주장 구조는 그대로 정당**하다. 단, 어텐션 주력은 baseline(SnapKV·H2O)과 같은 계열이 되므로 마지막 "차별점" 절이 필수다.

Part 1. 검정 방법별 상세 근거 — "왜 이걸 쓰는가"

1. AUC (ROC) — 컷오프를 지운다

- **왜 정확도가 아니라 AUC:** "컷오프 2.0에서 정확도 80%"는 신호 능력이 아니라 **컷오프 선택**을 반영. 컷오프 ↓ 원인 다 잡되 오탐 ↑, 컷오프 ↑ 반대. 컷오프에 안 휘둘리는 지표가 필요.
- **AUC가 답인 이유:** 컷오프 전 구간의 (FPR,TPR)를 이은 ROC의 아래 면적 = 컷오프 없이 **신호가 낼 수 있는 성능 전체**를 요약.
- **정의:** 양성·음성 하나씩 뽑을 때 양성 점수가 더 높을 확률. 0.65 = "원인이 평범한 줄보다 높을 확률 65%".
- **로그에 적합한 이유:** $AUC = U/(n_{pos} \cdot n_{neg})$ (Mann-Whitney U 동치). **순위만 쓰므로 정규성 가정 불필요** → 비대칭 로그 분포에 맞음.

2. 임계값 0.65 — 자의적 숫자가 아님

- **등식:** $r = 2 \cdot AUC - 1 \rightarrow AUC\ 0.65 \rightarrow r = 0.30$ (근사 아님, 등식).
- **Cohen 중간효과와 일치:** Cohen(1992) medium = r 0.30("주의 깊은 관찰자가 육안으로 알아볼 크기"). 0.65 = 중간효과 하한과 등식 일치. 안전계수·근사 없음.
- **2차 근거:** Vargha-Delaney $A \geq 0.64 = \text{medium} \rightarrow 0.65$ 는 medium 하단.
- **혼동 주의:** d 유도 점-이연 $r \approx 0.26 \neq \text{rank-biserial } 0.30$. AUC엔 반드시 rank-biserial(0.30) 인용.

3. 검정력 역산 — NO-GO의 뜻을 지키려고

- **왜 필요:** 표본수를 안 정하면 신호를 못 잡았을 때 **"신호 없음"인지 "표본 부족"인지 구분 불가**. 역산해두면 NO-GO가 신호 판별력을 반영.
- **수식(Hanley-McNeil 1982):** $n_{pos} = (z_{1-\alpha/2}\sqrt{V(A_0)} + z_{1-\beta}\sqrt{V(A_1)})^2 / (A_1 - A_0)^2$, $A_0=0.5$, $A_1=0.65$, $\alpha=.05$ 양측, power=.8.
- **결과:** 1:1 → 57, 1:4 → 37 → 하한 **$n_{pos} \geq 60$, $n_{eval} \geq 300$** . 실측 6,637 = 116배.
- **⚠ 범위:** 이건 AUC용. **2층 paired permutation엔 적용 불가** → 2층 검정력은 별도 시뮬(현재 빈칸).

4. 순열검정 — 우연 배제

- **왜:** AUC가 0.65 넘어도 우연일 수 있음 → 라벨 5,000회 셔플로 "우연히 이만큼 나올 확률" 직접 계산.
- **수식:** $p = (\text{count}+1)/(B+1)$, $|\text{perm}-0.5| \geq |\text{real}-0.5|$ 카운트. B=5,000, 양측, seed 42.
- **왜 양측:** 표본수가 $z_{1-\alpha/2}=1.96$ (양측)으로 산출 → 검정도 양측 통일.

5. McNemar — 두 압축기 비교의 핵심

- **왜 평균 비교가 아니라:** 두 압축기가 **같은 원인 줄**을 채점 → 강하게 상관(쉬운 줄 둘 다 보존, 어려운 줄 둘 다 제거). 독립인 척하면 **분산 오추정**. McNemar는 공유분 조건부 제거로 상관 처리.
- **왜 일치쌍(a·d) 제외 — 산수:** 보존율 차이 = $(a+b)/n - (a+c)/n = (b-c)/n$. a 상쇄, d 부재 → 차이값에 a·d가 애초에 없음(정보 없음).
- **수식:** $\chi^2 = (b-c)^2/(b+c)$, df=1. 표본 작으면 $(|b-c|-1)^2/(b+c)$, $b+c < 25$ → 이항 정확검정.
- **왜 정당(두 전제):** ① 모델 1회 실행 → Dietterich(1998)가 이 경우 McNemar 지목. ② 짝 단위 독립 → 라인은 독립 아님(한 버스트에 원인 수백 줄 쏠림) → **단위를 버스트로 잡아** 독립성 확보.
- **승부처:** 흔한 ERROR 원인은 둘 다 보존(a)=승부 아님. 승부 = 비-ERROR 원인 중 한쪽만 보존(b vs c). **PASS = b > c**.

6. BH-FDR (+Holm/BY) — 60번 검정하니까

- **왜 필요:** 60검정(3층×4baseline×5압축비)이면 다 차이 없어도 **평균 3개(60×.05)**가 우연 유의.
- **왜 Bonferroni 아니고 BH:** Bonferroni(0.05/60≈0.00083)는 진짜 차이도 버림. BH는 "고른 것 중 가짜 비율(FDR)"만 5% → 검정력 높음.
- **수식:** BH $p(k) \leq (k/m) \cdot \alpha$ / Holm $p(k) \leq \alpha/(m-k+1)$ / BY $p(k) \leq (k/m) \cdot (\alpha/c)$, $c \approx 4.68$.
- **왜 셋 다:** 60검정이 같은 라인 공유해 얽힘 → BH 독립 가정 흔들림 → 얽힘에 안전한 **Holm 병기**, BH가 잡은 게 Holm에서도 살면 신뢰. BY는 최후.

7. 부트스트랩 BCa CI — 실험을 다시 못 하니까

- **왜:** 차이 출렁임을 알려면 실험 반복해야 하나 불가 → 복원추출 10,000회로 흔들림 흉내.
- **왜 BCa:** 보존율 0~100%라 천장(90%)에 붙으면 분포 비대칭 → 단순 백분위(대칭 가정)는 어긋남 → BCa가 치우침 보정.
- **왜 pair 단위:** $\text{diffs} = \text{rate}_A - \text{rate}_B$ 를 통째로 재표집. 따로 뽑으면 "함께 움직임" 사라져 분산 오착.
- **판정:** 95% CI 하한 > 0 유의. (2층은 McNemar/순열 p<0.05 병행 — BCa 대응이 근사.)

8. 왜 "한 쌍씩"만 비교

- McNemar 2×2는 두 방법 전용(네 칸 = A×B). 셋이면 안 담김 → **우리(어텐션 압축기) 고정 + 상대만 바꿔 2개씩**.
- 질문이 "우리가 각 baseline을 이기나"지 "1등이 누구냐"가 아니라 두 개씩이 맞음. (1등 뽑기면 Friedman.)

Part 2. 카테고리 정리 — 1·2층

1층 원인 보존율 (Tier-1)

항목	내용
주 목적	같은 압축률에서 원인 라인을 누가 더 많이 살리나. 모델 정답률과 무관한 안전판 (floor에 안 흔들림).
평가 대상	정답지(G) 대비 원인 라인 생존율. 이진(rule=any), 층화(전체 / 비-ERROR / 앞쪽 풀림). 단위 = 버스트.
왜 이 검증	AUC(컷오프 제거·순위기반) · McNemar(짝 상관 처리, b>c) · BH-FDR+Holm/BY(60검정 보정) · Bootstrap BCa(비대칭 보정, 하한>0). ▶ 상세는 Part 1.
우리 주장	"고압축·하드케이스(비-ERROR)에서, 최고 baseline이 원인 0개 보존한 케이스를 우리가 1개+ 보존한다." (실무 근거: 원인 0개 = 진단 불가)

2층 제약형 RCA 정답률 (Tier-2)

항목	내용
주 목적	보존율 우위가 실제 RCA 성능 향상으로 이어지나 (결정타 검증). = 답지 채점 .
평가 대상	압축 방식만 바뀌 K지선다 RCA 정답률 델타. FullCache 짝대조로 C→W (원본 정답·압축 오답) 분리.
왜 이 검증	paired permutation(B=5,000·양측·α.05·seed 42) 주검정 · Bootstrap BCa(하한>0) · Delta 임계값 0.5×s (Cohen d medium; 1층 0.3(r척도)과 다름) · 주지표 rank-difference (Hit@k·MRR·percentile은 secondary) · 다중비교는 family=1로 좁힘.
우리 주장	"보존율 우위가 제약형 RCA 정답률 상승으로 이어진다 (사전등록 임계값 초과 + 통계 유의)."

baseline (양 층 공통) — 꼭 이 조합이어야 하는 이유

baseline	역할 · 안 쓰면 뚫리는 반박
random KV	바닥선. 없으면 "로그가 잉여라 아무거나 지워도 원인 남는 것 아니냐"에 무방비. random을 못 이기면 우리 신호가 한 일이 없는 것.
레벨 필터	실무 최저선. 없으면 "그냥 ERROR/WARN만 남기면 되잖아, 압축기 왜 써"에 답 없음.
SnapKV · H2O	최강 경쟁(같은 KV 층위). 이겨야 "범용 KV 압축보다 낫다" 성립. 없으면 개선 기준 자체가 없음.
StreamingLLM · PyramidKV	계열 커버(최근성·층별 배분). 하나만 이기면 "그 방법이 약해서"라 반박 → 계열을 덮어야 "어떤 범용 전략도 놓친다"가 성립.

baseline 통합 주장

"바닥(random)부터 최강(SnapKV/H2O)까지 **전 스펙트럼을 같은 조건에서 이긴다**. baseline은 논문 수치 인용이 아니라 **kvpress로 직접 재현 + 구현 감사**한 값만 쓴다(KVDiagnosis가 PyramidKV를 구현 결함으로 제외했듯, '소수점 똑같음' 같은 신호 점검)."

Part 3. 차별점 문장 — 어텐션 주력의 필수 방어

반드시 명시할 것

어텐션이 주력이면 **우리 압축기와 SnapKV·H2O baseline이 둘 다 어텐션 계열**이 된다. 따라서 "우리 어텐션 vs 재네 어텐션"의 차별점을 주장에 못 박지 않으면 **"SnapKV랑 뭐가 다르냐"**가 그대로 남는다.

차별점 문장(택1 이상, 실제 설계에 맞게 채택):

- 신호 결합형:** "우리는 순수 어텐션이 아니라 **어텐션에 로그 고유 신호(레벨·회귀도·시간·위치)를 결합**해 중요도를 매긴다. 범용 어텐션(SnapKV·H2O)이 놓치는 비-ERROR·중간 원인을, 로그 신호가 보정한다."
- 적용 지점형:** "같은 어텐션이라도 **로그 구조(버스트·템플릿·노드) 단위로 예산을 배분**한다는 점이 범용 균일 예산과 다르다."
- 검증 프레임형:** "우리 기여는 압축기 자체가 아니라 **로그 RCA에서 원인 보존을 사전등록 기준으로 검증하는 평가 틀**이며, 어텐션 압축기는 그 틀 위의 한 구현이다."

주의

어떤 차별점을 택하든, 그것을 **2층 주장과 baseline 비교표에 명시**해야 한다. 차별점이 "신호 결합"이면 ablation에 **어텐션 단독 vs 어텐션+로그신호**가 반드시 들어가야 "로그 신호가 실제로 기여했다"가 증명된다. 이 한 줄이 빠지면 어텐션 주력은 "SnapKV 변형"으로 읽힌다.

전거. 평가방법_정당성.md(McNemar·BH-FDR·Bootstrap 원리) · (검정력_분석)case_count.md(AUC·Hanley-McNeil 표본수) · killswitch_freeze_v3.md(관문① 판정식) · 평가지표.md(v7 사전등록 부속서) · description.md(보존율 채점). 원전: McNemar 1947 · Dietterich 1998 · Benjamini-Hochberg 1995 · Benjamini-Yekutieli 2001 · Holm 1979 · Efron-Tibshirani 1993 · Hanley-McNeil 1982 · Cohen 1992.