

LOGPRESS · 평가설계

압축을 어떻게 평가할 것인가

1·2·3 층 평가 — 무엇을 재고 · 어떻게 재고 · 어떤 검정으로

평가는 3 층 구조

각 층이 서로 다른 질문에 답한다. 오늘은 1 층은 간략히, 2,3 층 검정을 중심으로.

1

정보 보존

원인을 잘 남기나 (품질)

메트릭

- 보존율
- marginal gain

2

효율 / 비용

가볍고 빠르냐 (비용)

메트릭

- KV memory 절감
- TTFT · throughput
- inference time

3

출력 충실도

원본과 같게 판단하나

메트릭

- log-probability
- perplexity
- KL divergence

이번 발표 범위 1 층은 이미 정립 → 간략히. 2,3 층 검정이 무엇을 하는지를 설명한다.

1 층 — 정보 보존 (간략)

무엇을 재나

정답 원인 라인 중 , 압축 후 살아남은 비율 = 보존율

$$\text{보존율} = |G \cap C| / |G|$$

G = 정답 라인 전체 **C** = 압축기가 남긴 라인

핵심 지표 · marginal gain = 보존율 (LogPress) - 보존율 (레벨필터)

어떤 검정

McNemar

두 압축기가 같은 라인을 채점 → 짝진 승부 . 한쪽만 살린 라인만 비교 ($b > c$).

BH 보정

검정 60 번이라 우연 승리가 뜸 → 가짜 비율만 5% 로 눌러 진짜 차이를 살림 .

세부는 기존 평가설계 문서에 정립되어 있어 오늘은 요약만 .

2 층 — 효율 / 비용 : 지표가 무엇을 하나

무엇을 원인을 유지하면서 메모리 · 속도를 얼마나 줄이나 . 왜 실측 메모리 · 속도는 이진 승패가 아니라 측정값 → McNemar 안 씀 .

KV memory reduction

압축률별 KV 캐시가 얼마나 작아지나 . 같은 GPU 에서 더 긴 로그 수용 .

TTFT (Time To First Token)

첫 토큰까지 시간 . 긴 로그 읽는 (prefill) 시간이 여기 다 들어감 — 압축 효과 직격 .

throughput

초당 처리 토큰 수 . KV 가 작아지면 ↑ . 높을수록 좋음 .

inference time

입력 ~ 답 끝까지 전체 추론 시간 .

핵심 프레이밍 : $\text{retained evidence 단위당 절감} = \text{절감한 메모리 (또는 시간)} / \text{보존한 원인 라인 수}$

3 층 — 출력 충실도 : 원본과 같게 판단하나

출력 분포란


모델이 답 후보마다 매긴 확률의 묶음 . 제일 높은 걸 고른 게 '정답' .

답이 같다 ≠ 분포가 같다

정답률은 프론티어도 3.9~12.5% 로 낮아 압축 차이가 안 보인다 .

→ '맞았나' 대신 '확률 지형이 같나' 로 예민하게 본다 . 정보를 잃으면 확률이 뭉개진다 .

원본 vs 압축본 출력 분포 — 지형이 비슷하면 정보 보존 ✓



3 층 세 지표가 무엇을 하나

1

log-probability

정답 토큰에 준 확률 (로그)

0 에 가까울수록 정답을 확신 . 정답 ' 하나 ' 의 확신도를 본다 .

2

perplexity

$e^{(-\text{평균 log-prob})}$

log-prob 를 ' 체감 혼란도 ' 로 바꾼 값 . 낮을수록 안 헛갈림 = 좋음 .

3

KL divergence

$\sum P(i) \cdot \log(P(i)/Q(i))$

두 분포가 얼마나 벌어졌나 . 0 이면 같음 , 클수록 다름 . 분포 ' 전체 ' 를 본다 .

묶어 보면 log-prob·perplexity = ' 정답 하나의 확신' , KL = ' 분포 전체의 차이' . 둘을 함께 본다 .

다음 액션 — 2 층 평가 구체화

1.3 층 빠대는 정립 → 다음은 2 층 (효율 / 비용) 을 실제 측정 가능하게 못 박는다 .

1

측정 조건 고정

연산속도를 잘 GPU·배치·컨텍스트 길이를 통일 (공정 비교의 전제).

2

단위당 절감 확정

retained evidence 단위당 절감 계산식을 명확히 정의 .

3

2 층 검정력 채우기

필요 표본수 산정 — 1 층 AUC 검정력은 2 층에 못 쓰므로 별도 .

4

KV memory 측정법

GPU 피크 측정 vs 이론 계산 중 방식 확정 .