

로그 RCA KV Cache 압축 프로젝트 모델 선정 기준 및 근거

어떤 LLM을 *backbone*으로 써야 하는가 — 제약 역산 · 선행연구 관례 · 도구 지원 · 성능 바닥 대응

2026 · 통합 문서 부속 자료

한눈에 — 결론 먼저

주력 backbone: Llama-3.1-8B-Instruct (128K 컨텍스트 · KV 논문 최다 사용 · KVPress 지원)
2차 backbone: Qwen2.5-7B-Instruct 또는 Qwen3-8B (일반화 증명용 · 추론력이 높아 2층 floor 완화)
도구: NVIDIA kvpress (H2O·SnapKV·StreamingLLM·PyramidKV 등 baseline 일괄 재현)
2층 RCA 태스크: 제약형(객관식/원인 라인 지목) 으로 설계해 성능 바닥(floor) 회피

1. 프로젝트에서 역산한 5가지 필수 기준

모델은 취향이 아니라 프로젝트 제약에서 결정된다. 아래 다섯 조건을 모두 만족하는 좁은 교집합이 선택지다.

① 오픈 가중치 + KV 내부 접근 (절대조건)

KV를 직접 버리는 개입이 필요하므로 API 모델(Claude·GPT)은 원천 배제된다. KV 캐시 압축은 추론 엔진 내부에서 일어나며 모델 내부 접근을 요구하기 때문에, 추론 계층이 불투명한 상용 API로는 불가능하다. 기획서 §12의 '오픈 모델 필요'를 확정하는 근거다.

② KVPress가 지원하는 아키텍처 — 사실상 선택을 결정

baseline 재현이 1~2개월차 핵심 과제인데, NVIDIA kvpress가 30개 이상의 KV 압축 방법을 HuggingFace 후크로 드롭인 제공한다. 모델 수술 없이 지원 아키텍처의 어떤 체크포인트에도 붙는다. 따라서 H2O·SnapKV·StreamingLLM·PyramidKV를 직접 재구현하지 않고 그대로 가져올 수 있어, 모델을 이 지원 목록 안에서 고르는 것이 강하게 유리하다.

kvpress 공식 지원 아키텍처: LlamaForCausalLM · MistralForCausalLM · Phi3ForCausalLM · Qwen2ForCausalLM · Qwen3ForCausalLM · Gemma3. 압축은 *prefill 단계에 적용* — 본 프로젝트의 '전 레이어 일괄 삭제(§7)' 설계와 정확히 맞는다.

③ baseline 논문들이 실제로 쓰는 backbone과 일치

거의 모든 KV 압축 논문이 두세 모델로 수렴한다. 같은 backbone을 써야 우리 결과를 기존 곡선과 직접 비교할 수 있다.

선행 KV 압축 연구	사용 backbone
PyramidKV	LLaMa-3-8B-Instruct · Mistral-7B-Instruct (일부 70B)
ZigZagKV	LLaMa-3.1-8B-Instruct · Mistral-7B-Instruct-v0.3
DynamicKV	LLaMA3-8B · Mistral-7B-v0.2 · Qwen2-7B · InternLM-2.5
KV-Compress	Llama-3.1-8B-Instruct · Mistral-7B-Instruct-v0.2

정리: Llama-3(1)-8B-Instruct와 Mistral-7B-Instruct가 사실상 업계 표준. Qwen 계열이 세 번째 관례.

④ 128K 컨텍스트 — 100K 로그 수용

로그가 케이스당 약 100K 토큰(기획서 §1)이므로 128K급이 필요하다. Llama-3.1-8B(128K), Qwen2.5-7B / Qwen3-8B(128K+) 는 충족한다. 반면 Mistral-7B-v0.3는 32K라 전체 로그엔 부족하다(윈도우·절단 실험엔 여전히 유효).

⑤ 소규모 GPU 예산 — 7~8B

7~8B 모델은 단일 GPU(16~24GB)에 적재 가능하며 4-bit 양자화도 병행할 수 있다. 애초에 100K 컨텍스트에서 KV 캐시가 VRAM을 잠식하는 그 상황이 이 프로젝트의 연구 대상이므로, 모델 자체는 가벼워야 실험 반복이 가능하다.

2. 구체적 모델 추천

용도	모델	근거
주력 backbone	Llama-3.1-8B-Instruct	128K · KV 논문 최다 사용 · KVPress 지원 · baseline 직접 비교
2차 backbone(일반화)	Qwen2.5-7B-Instruct / Qwen3-8B	128K · KVPress 지원 · 추론력↑ → 2층 floor 완화
윈도우 실험용(선택)	Mistral-7B-Instruct-v0.3	KV 논문 표준이나 32K라 전체 로그엔 부적합

- KV 압축 논문은 관례적으로 최소 2개 backbone으로 일반화를 보인다(ZigZagKV·DynamicKV). Llama-3.1-8B를 메인, Qwen 계열을 보조로 붙이는 조합을 권장.
- 반드시 Instruct/chat 버전 사용 — RCA는 지시 따르기가 필요해 base 모델은 부적합.
- 가중치 접근이 필요하므로 Llama·Qwen 모두 HuggingFace에서 라이선스 동의 후 체크포인트를 받아 로컬 적재.

3. 2층(RCA delta) — 성능 바닥 문제를 정면 대응

기획서 §9에서 경고한 '보존율↑가 RCA↑를 보장하지 않는다'의 실제 데이터가 확인됐다. RCA는 프런티어 모델조차 바닥권이라, 작은 오픈 모델을 그대로 던지면 delta 측정 자체가 불가능해질 수 있다.

벤치마크 / 조건	성능	시사점
OpenRCA · Claude 3.5 · oracle telemetry	5.37%	프런티어+정답 힌트도 한 자릿수
OpenRCA · Claude 3.5 · 샘플링	3.88%	현실 조건에선 더 낮음
OpenRCA 2.0 · 프런티어 11종 평균	20.7%	정확한 원인 집합 복구율(개선판)
→ 오픈 8B 모델 · 자유서술 RCA	≈ 0% 우려	floor에 깔려 delta 측정 불가 위험

대응책 (셋 중 택1 또는 병행):

- (a) 2층 태스크를 제약형으로 — 권장. 자유서술 대신 '원인 후보 K개 중 선택' 또는 '원인 라인 지목'으로 바꿔 바닥에서 띄운다. OpenRCA도 프롬프트에 가능한 원인 목록을 미리 제공해 채점 안정성을 확보한다.

- (b) 추론 특화 모델 사용. DeepSeek-R1-Distill-Qwen-7B/14B 등은 KV 압축 연구에서 이미 쓰이며 (Hold Onto That Thought, kvpress 지원) 추론력이 높아 floor를 올린다.
- (c) 1층(보존율)을 주력, 2층은 방향성만. 이미 §9에서 정한 안전판 전략을 유지하고, 2층은 '보존↔ 성능 관계 최초 측정'으로 프레이밍한다.

주의: 모델 선택은 '하면서 정하는' 항목이 아니라 2층의 생사를 가르는 관문이다. 예비 실험 단계에서 후보 모델의 RCA 바닥 성능부터 실측해 floor 여부를 확인한 뒤 2층 태스크 형태를 확정해야 한다.

4. 확정 제안 및 §12 반영

기획서 §12의 '모델 선택 — 크기 미정 ⌚' 항목을 다음으로 갱신할 것을 제안한다.

항목	확정안	상태
주력 모델	Llama-3.1-8B-Instruct (128K)	✅ 제안 확정
2차 모델	Qwen2.5-7B-Instruct 또는 Qwen3-8B	✅ 제안 확정
압축 도구	NVIDIA kvpress (baseline 30+종 내장)	✅ 제안 확정
2층 RCA 태스크	제약형(객관식/원인 라인 지목)	✅ 제안 확정
floor 실측	후보 모델 RCA 바닥 성능 예비 측정	⌚ 예비 실험 최우선

한 문장 요약 KV 내부 접근·KVPress 지원·baseline 비교 가능성·128K·단일 GPU라는 5개 제약의 교집합으로 Llama-3.1-8B-Instruct를 주력, Qwen2.5-7B를 2차 backbone으로 확정하고, RCA 성능 바닥을 피하기 위해 2층은 제약형 태스크로 설계한다.

부록. 근거 출처

주장	출처
KV 압축은 모델 내부 접근 필요 · API 불가	gotcontext.ai, NVIDIA kvpress 해설 (2026-05)
kvpress 30+종·지원 아키텍처(Llama/Mistral/Phi3/Qwen2/Qwen3/Gemma3)	github.com/NVIDIA/kvpress (base_press.py SUPPORTED_MODELS)
PyramidKV backbone: LLaMa-3-8B · Mistral-7B	PyramidKV (arXiv:2406.02069)
ZigZagKV: Llama-3.1-8B-Instruct · Mistral-7B-Instruct-v0.3	ZigZagKV (arXiv:2412.09036)
DynamicKV: LLaMA3-8B·Mistral-7B·Qwen2-7B·InternLM-2.5	DynamicKV (arXiv:2412.14838)
KV-Compress: Llama-3.1-8B · Mistral-7B-Instruct-v0.2	KV-Compress (arXiv:2410.00161)
OpenRCA: Claude 3.5 = 5.37%(oracle)/3.88%(샘플링)	OpenRCA, ICLR'25 (netman.aiops.org)
OpenRCA 2.0: 프런티어 11종 평균 20.7%	OpenRCA 2.0 (arXiv:2606.27154)
추론 모델 + kvpress 사용(DeepSeek-R1-Distill 등)	Hold Onto That Thought (arXiv:2512.12008)

주의: 모델 컨텍스트 길이·버전은 릴리스에 따라 바뀔 수 있으니, 확정 직전 각 모델의 HuggingFace 카드에서 컨텍스트 창과 라이선스를 재확인할 것. 일부 arXiv ID(2606.2512)는 최신 프리프린트로 미심사 상태.