

LogPress · 중간 보고

로그 RCA 증거 보존형 KV Cache 압축

Week 0-1 진행 현황 · 환경 검증 완료 · 킬스위치 착수

보고 범위 **Week 0 산출물 · A/B 트랙 실적**

작성 **Role D (리드 / 평가)**

일자 **2026-07-20**

무엇을 하는 프로젝트인가

장애 로그를 LLM 에 넣을 때 문맥이 넘쳐 압축이 필요하다 . 기존 KV 압축은 ' 눈에 띄는 줄 ' 을 남기지만 , 실제 장애 원인은 **평범한 INFO 줄에 숨어 있다** . LogPress 는 로그 고유 신호 (레벨 · 희귀도 · 위치) 로 **증거가 되는 줄을 살려 압축한다** .

프로젝트 생사를 가르는 관문 3 개 — 이 순서로 막히면 뒤가 무의미



킬스위치

3 주차 · 담당 D

하드케이스 표본이 충분한가
신호에 구별력이 있는가

진행 중



kvpress PoC

9 주차 · 담당 C

마스크 → 전 레이어
KV 삭제가 동작하는가

착수 가능



Nezha 전처리

11 주차 · 담당 B

원인 라벨을 라인 단위로
매핑할 수 있는가

사전조사 완료

임계 경로 : 0 단계 → ① 킬스위치 → 매핑 → ② PoC → LogPress → 1 층 평가

Week 0 산출물 — 내용 확정 , 서명 단계

실험을 시작하기 전에 못 박아야 하는 4 가지 . 결과를 본 뒤 기준을 바꾸면 그 순간 검정이 무효가 된다 .

01	판정식 프리즈 killswitch_freeze_v2.3.md	순환 논리 제거 + 매칭 규칙 · 표본 단위 · 재현성 규약까지 확정 → 서명만 남음	전 항목 확정
02	재현성 규약 seeds.yaml · splits/ · seed_utils.py	난수원 8 종 · 동결 파일 6 종 목록화 · D 검열 (O/X) 후 커밋 · 서명	초안 완료
03	라이브러리 버전 핀 requirements.lock	kvpress↔transformers 호환성 실측 해소 · Linux 재현만 남음	조합 확정
04	검정력 분석 임계값 감사 문서	ROC 검정력으로 n_hard 근거 확보 · 실측이 하한을 22 배 초과	완료

최대 기술 리스크를 실측으로 해소

기획 단계에서 지목한 '**첫 지뢰**' — kvpress 는 transformers 의 KV 캐싱 구조가 바뀔 때마다 깨진 이력이 있다 (v4.48 · PR #115). 임포트는 성공해도 **압축 단계에서 조용히 실패**하는 유형이라 , 실제로 압축을 걸어봐야만 확인된다 .

KV cache sequence length

48

→

24

검증 통과

압축 전 (1, 2, 48, 128)

압축 후 (1, 2, 24, 128) · 36 layers 전부

검증 모델

Qwen2.5-3B-Instruct (로컬 GPU)

적용 **press**

KnormPress · compression_ratio 0.5

캐시 접근 경로

DynamicCache.layers[0].keys/values

재현 기록

kvpress_tf4_shape_result.md

의미 압축이 실제로 동작함이 확인되어 C 트랙 (매핑 · 압축) 이 착수 가능한 상태가 됐다 . 부수 소득으로 이 버전에서 통하는 캐시 접근 경로까지 확보 — C 가 헤맬 구간이 줄었다 .

재현 가능한 조합을 고정했다

버전이 다르면 같은 코드도 다른 숫자를 낸다. 결과 (AUC) 를 보기 전에 동결하는 것이 원칙.

검증 완료 조합

transformers	4.57.6
kvpress	0.5.4
torch	2.8.0
numpy	2.4.6

transformers 5.x 는 배제 — 메이저 변경으로 캐시 구조 위험

공식 lock 까지 남은 절차

- 1 GPU 서버 접속 → CUDA · Python 확정
- 2 그에 맞는 torch 빌드 설치
- 3 통계 라이브러리 추가 (scipy · statsmodels · sklearn)
- 4 동일 압축 검증 재실행 (48 → 24)
- 5 pip freeze → requirements.lock 커밋

로컬 (Windows) freeze 는 그대로 쓰지 않는다 — CUDA 빌드가 다르다

동결 기한 : 킬스위치 판정 (3 주차) 이전 — 결과를 본 뒤의 동결은 사전등록 효력을 잃는다

Thunderbird 전수 스캔 완료

2 억 1,121 만

전체 로그 라인 전수 스캔

parse error 0 건

3,248,239

원인 (이상) 라인

전체의 1.5%

14,939

하드케이스

레벨 필터가 100% 놓침

8,846

중간 위치 하드케이스

하드케이스의 59%

포함 관계 원인 ⊃ 하드케이스 ⊃ 중간 위치 — 총이 겹치면 총화 채점이 성립하지 않는다

완료 항목

- 스트리밍 파서 — 2 억 줄 전수 처리 검증
- 레벨 기준 정규식 — 45 개 육안 검증 , 오탐 0
- 난이도 총화 파일 (killswitch_stratified.csv)
- 파싱 함정 해결 — 콜론 중첩 · BOM 이슈

Nezha 사전조사 — 설계 영향 있음


전체 101 케이스 중 원인 62% 가 metric(CPU· 네트워크) 에 있어 로그 압축으로 검증 불가 . 로그 원인은 38 개이며 전부 INFO 레벨로 하드케이스 조건은 충족하나 , 독립 표본은 17 개로 통계가 약하다 .

→ 핵심 성과는 1 층 (Thunderbird) 에 두고 , Nezha 는 방향성 검증으로 활용 제안

표본 수 우려를 정면으로 검증했다

하드케이스가 14,939 줄이지만 Drain3 로 묶으면 템플릿은 **9 종뿐** — 상위 4 종이 99.2% 를 차지한다 . 라인으로 세면 '**1 개 사건의 복사본**' 을 표본 수천 개로 착각하게 된다 (의사복제). 그래서 독립 단위를 다시 정의했다 .

독립 표본 1 개 = (노드 , 템플릿 , 5 분 시간창) 같은 노드 · 같은 템플릿이 5 분 안에 연달아 나오면 1 개로 센다



22 배

가장 보수적인 기준에서도
하한 300 을 22 배 초과

검정력 근거

ROC 검정력 공식 (Hanley-McNeil 1982) 상 필요 소수 클래스는 약 30-37 개 . 300 은 의사복제 방어를 위한 보수적 설정이며 , 실측이 이를 크게 상회해 표본 리스크는 해소 .

판정식에서 순환 논리를 제거했다

라벨을 정하는 축과 신호로 맞추는 축이 겹치면 ' 위치로 정의한 것을 위치로 맞히는 ' 자기충족이 된다 .

v1 — 순환 발생

채점 기준 (라벨)

alert 태그 + 중앙 위치 (0.25~0.75)

맞추는 신호

희귀도 + 위치

v2 — 고리를 끊음

채점 기준 (라벨)

alert 태그만 (위치 제외)

맞추는 신호

희귀도 + 위치 (유지)

라벨이 위치와 독립이므로, 위치를 신호로 써도 순환이 아니다 — 오히려 독립 예측변수가 된다

의사복제 방어

CI 를 라인이 아닌 Drain3 템플릿 클러스터 단위로
부트스트랩

비교군 매칭

같은 노드 · 유사 시간대로 교란 통제 , 위치는
매칭하지 않음

p- 해킹 차단

규칙 확정 · 커밋 후에 음성 재추출 → 그 다음 AUC
측정

비교군 매칭 규칙 — 실측 근거로 확정

현행 비교군은 무작위 균등 추출이라 부적합 판정 . B 가 범위별 매칭률을 실측해 규칙을 확정했다 .

시간 범위

± 1 시간 (같은 노드)

매칭률 실측 — 같은 5 분 96.9% / ±30 분 99.4% / ±1 시간 99.5% / ±6 시간 100%. 손실 0.47% 에서 교란 통제와 균형

실패 처리

제외 금지 · 2 단계 풀백

①±1 시간 → ②같은 노드 전 기간으로 시간만 완화 → ③그래도 실패 시 민감도 분석에 별도 보고

함께 봉인한 항목 · 음성 추출 seed 42 · 순열검정 seed 7 · 5,000 회 고정 (증가 금지) · 노드 식별 불가 31 개 제외 기록

트랙별 다음 2 주

A 인프라

GPU 서버에서 lock 확정
Baseline 4 종 재현 착수

B 데이터

seed 42 로 음성 재추출
→ splits/ 에 커밋

C 매핑 / 압축

kvpress BasePress 구조
사전 조사 착수

D 리드 / 평가

4 인 서명 · 커밋
→ AUC 측정 착수

요약

세 개의 큰 리스크가 실측 · 설계로 해소됐다

기술 리스크	kvpress ↔ transformers 호환성	KV 48 → 24 실측 확인
통계 리스크	하드케이스 표본 부족 우려	독립 표본 6,722 — 하한의 22 배
방법론 리스크	순환 논리 · p- 해킹 여지	라벨 / 신호 분리 + 시드 봉인
남은 것	4 인 서명 · 커밋	그 다음 음성 재추출 → AUC