

Kill-switch 프리즈 재검증

— 제외 규칙 확정 · 위치 신호 결함 발견과 재정의

Week 2 정기회의 · Role D (리드 / 평가)

한 줄 요약 프리즈를 데이터로 재검증하며 표본 · 제외 규칙을 확정하고 , 현재 위치 정의로는 신호가 구조적으로 무력화됨을 발견 → 원인 규명 후 재정의안까지 마련

1. 프리즈 재검증 — 확정 사항

데이터로 문서 전체를 대조 · 검증하여 수치와 규칙을 확정 (v3_2 → v3_9)

표본 정본 확정

14,819 줄 / 6,637 관측단위

원본 14,939 에서 제외 120 줄

제외 규칙 3 종

태그 무관 구조적 기준

단일노드 / 식별불가 / 본문없음

검정 설계 정합

양측 통일 · 결합식 확정

로지스틱 회귀 + 3 신호 병기

위치 결함 발견

재정의안 확정

파일전역 → 컨텍스트 윈도우

2. 무엇을 , 왜 제외했나

원본 14,939 줄 → 제외 120 줄 → 정본 14,819 줄 . 제외는 태그가 아니라 구조적 기준

CHK_DSK

13 줄

전량이 단일 관리노드 (tbird-admin1) 에 집중

→ 노드 변량이 없어 교란 통제 불가

숫자 # 노드

31 줄

노드명이 자리표시자 (#9#·#25#...)

→ 실제 기계 식별 불가 → 매칭 무의미

본문 없음 (t3)

76 줄

로그 메시지 칸이 빈 줄 (파싱오류 X)

→ 보존할 내용 없음 · 희귀도 계산 불가

합계 120 줄 제외 (본문없음 77 줄 중 1 줄은 # 숫자# 와 중복 → 순증 76) → 정본 14,819 줄 / 6,637 관측단위

3. VAPI 를 뺀 게 아니다 — 기준을 바꿨다

같은 결과 (30 줄 제외) 라도 " 왜 뺐나 " 에 따라 신뢰도가 갈림

처음 근거 (기각)

"VAPI 는 322 만 줄로 흔하고 레벨필터가 처리 "

→ 이는 **VAPI 전체 얘기** . 하드케이스로 남은 **30 줄은 오히려 필터가 놓친 표적** . 집단 성질로 잔여 개체를 판단한 오류 .

바뀐 기준 (채택)

제외 기준 = 태그가 아니라 " 본문 없음 "

본문 빈 76 줄을 일괄 제외 → VAPI 30 줄은 그 안에 포함되어 함께 빠짐 .
태그별 자의적 제외 의심 제거 .

본문 없음 76 줄 구성 : VAPI 30 · EXT_FS 33 · MPT 8 · CPU 5 · SCSI 1 — 5 개 태그에 걸침 . VAPI 만 빼면 같은 성질 46 줄이 남아 자의적 .

심사 대응 "VAPI 30 줄은 제외했습니다 . 단 태그가 VAPI 라서가 아니라 본문이 비어서입니다 .
본문 빈 76 줄을 태그와 무관하게 모두 제외했고 , VAPI 는 그중 일부입니다 ."

4. 프리즈 변경사 (v3_2 → v3_9)

움직이는 과녁을 하나로 못 박는 과정 — 수치 · 규칙이 세 번 조정됨

항목	v3_2 (초기)	v3_9 (현재)	근거
하드케이스	14,939 줄	14,819 줄	제외 120 줄 반영
관측단위	6,722	6,637	제외 37 버스트
양성 하한 n_pos	40	60	1:1 주검정 요건 57
검정 방향	one-sided	양측 (two-sided)	표본수 z=1.96 정합
결합 수식	미정	로지스틱 회귀	p- 해킹 차단 4 조항
템플릿 내부 AUC	방어책	폐기 (계산불가)	양 · 음 교집합 0
위치 정의	파일 전역	컨텍스트 윈도우	매칭 시 0.5 붕괴

5. 위치 신호 결함 발견 — 이번 주 핵심

이번 주 핵심

현재 위치 정의 (파일 전역) 로는 음성 매칭 후 AUC 가 구조적으로 0.5 로 붕괴 . 신호가 없어서가 아니라 설계가 신호를 지움 .

원인	실측 근거	대안 검토
위치 = 파일 내 시각 (상관계수 1.000) → 장애 몰린 " 시기 " 를 외우는 교란	매칭쌍 위치 차이 중앙값 0.000015 → 양성 · 음성 위치 사실상 동일 → 0.5	관측단위 내부 (②) 도 순수성 탓에 0.5 → 둘 다 탈락 구조적 문제 확인

재정의 (③) : 컨텍스트 윈도우 (노드 + 시계기준 1 시간) 내부 상대위치 . LLM 이 넣어준 문치 안에서 가운데를 놓치므로 (lost-in-the-middle), 위치도 문치 기준이 논리적으로 일관됨 .

6. 이번 발견의 의의

결과를 보기 전에 설계 결함을 잡음 — 사전등록 (프리즈) 의 목적 그 자체

만약 못 잡았다면

3 주차에 위치 $AUC \approx 0.5 \rightarrow NO-GO$.
신호가 없어서인지 정의가 잘못됐어서인지
구분 불가 $\rightarrow$ 원인 모른 채 프로젝트 위기

실제로 잡았기에

측정 전에 정의를 교정 .
결함이 " 정의 문제 " 임을 실측으로 규명 $\rightarrow$
올바른 기준으로 재설계 후 판정 진입

평가자 (D) 의 역할

성능 수치 산출이 아니라
" 그 수치가 믿을 만한가 " 를 보증

방법론 강점

규칙 선 (先) 확정 · 서명 · 커밋으로
p- 해킹을 구조적으로 차단

재사용 가능

같은 평가 파이프라인을
Tier-1·멘토 KPI 로 확장

7. 다음 주 (Week 3) 계획

킬스위치 판정을 위한 잔여 작업 — 환경 (A) 지연과 무관하게 진행 가능



위치 정의 확정 → 프리즈 \$4.3 반영

노드 +1 시간 창 내부로 확정, 문서 박제

D



원본 로그 수령 (양성 창 6,039 개)

위치 계산용 · 요청 완료, 대기 중

B



AUC 코드 작성 (합성데이터 검증)

환경 무관 · 서명 前 커밋 = 사전등록 증거

D



4 인 서명 + git commit

서명 이후에만 실측 — 사전등록 효력

전원

실질 병목은 코드가 아니라 서명 — 위치 확정 · 원본 수령 직후 서명이 Week 3 의 관문

8. 팀 트랙 진행 현황 (Week 0 → 1)

D 는 평가 · 리드 , B 는 데이터 / 프리즈 협의 , A 는 실험 환경 구축을 병렬 진행

	Week 0	Week 1	Week 2 (현재)
D 리드 · 평가	프리즈 설계 · 재검증 · 위치 재정의 → B 와 프리즈 상시 협의 → 표본 · 제외규칙 · 위치정의 확정		
B 데이터 · 라벨	D 와 프리즈 협의 · 데이터 정제 · 라벨 → Drain3 템플릿 · 레벨필터 완료 · 원본 로그 추출 대기		
A 실험 환경	로컬 GPU: Qwen·kvpress 검증 (48→24) → Week1: RunPod 이전 · requirements freeze · 7~8B 확인	Linux 서버 이전 · 버전 고정 · 양자화	