

# 무엇을 , 어디까지 할 수 있는가

결론을 앞세우기보다 , 지금 되는 것과 안 되는 것의 경계를 정직하게 그린다 . 이 경계가 이 발표의 뼈대다 .

## 지금 할 수 있는 것

현재 데이터셋으로 바로

- 보존율 곡선  
(proxy·baseline 4 종 )
- 신호 ablation ·  
keep\_mask 근거
- 템플릿 홀드아웃 · 재현성  
동결

## 지금은 못 하는 것

구조적으로 막힘

- 진짜 ‘원인’ 보존율 ( 라벨 없음 )
- 분산형 · 비국소 원인 검증
- 실시간 / 멀티홉 사슬 보존

## 조건 갖추면 되는 것

환경 제약만 풀리면

- Nezha 전처리 → 2 층  
RCA
- 2 차 backbone · GPU  
스왑
- floor 회피 추론모델

## 미래 과제로 남김

프로젝트 범위 밖

- 실시간 스트리밍 보존
- 학습 기반 KV
- 보존의 운영 가치

# 왜 여기서 선을 긋는가

## 모든 경계의 원인 = 데이터셋

**Thunderbird** — 표본은 많지만 ‘이상’ 라벨 ( 원인 아님 ) → 1 층은 proxy 까지 . **Nezha** — 진짜 ‘원인’ 라벨이지만 소규모 · 저부하 → 2 층의 유일한 근거이나 대표성 한계 .

## 같은 축인가, 갈라지는가

기준 하나 : 원 축 (KV 압축으로 원인 보존 ) 을 유지하면 ‘안’ , 축이 바뀌면 ‘밖’ .

### 프로젝트 ‘안’ — 이어갈 것

*같은 축의 자연스러운 다음 첩터*

- Nezha 원인 라벨로 보존→ RCA 검증
- 희귀도 재설계 ( 라벨 누수 끊기 )
- keep\_mask 설명가능성

### 프로젝트 ‘밖’ — 갈라지는 새 문제

*비슷해 보여도 축이 다른 연구*

- 실시간 스트리밍 보존 ( 설계 변경 )
- 다른 로그 태스크용 KV 압축
- 학습 기반 KV · 보존의 운영 가치

*발표 · 논문에선 ‘밖’ 을 related / future work 로 분리 — 섞으면 기여가 흐려진다 .*

정직한 수위 “보존이 RCA 를 향상시킨다” 가 아니라 — 저장 로그의 사후 분석에 한정해 , 보존과 성능의 관계를 처음으로 쟀다 .

# McNemar — 두 방법 중 누가 원인을 더 남겼나

## 1 무엇을 하나 — 2×2 로 놓고 본다

|             | baseline 보존 | baseline 제거 |
|-------------|-------------|-------------|
| LogPress 보존 | a           | b           |
| LogPress 제거 | c           | d           |

회색 (a·d) 같은 판정 → 버림 . 주황 (b·c) 엇갈림 → 이것만 씀 .

두 보존율의 차이 =  $(b - c) / n$  — 공통 a·d 는 상쇄되어 애초에 안 들어감 .

숫자로 a=800, d=50 은 버리고 b=90, c=40 만 사용 .  
 $\chi^2 = (90-40)^2 / (90+40) \approx 19.2 \rightarrow p \approx 0.00001$  (유의)  
 $b(90) > c(40) \rightarrow \text{LogPress 가 더 많이 보존 .}$

## 2 핵심 원리 — 엇갈린 것만 동전 던지기

둘이 실력이 같다면 , 엇갈린 쌍이 어느 쪽으로 갈 확률은 반반이어야 한다 . → 불일치쌍 b+c 개를 공정한 동전 b+c 번 던지기로 보고 , b 가 c 보다 유의하게 쏠렸는지 확인한다 .

### ? 내가 부딪힌 질문

Q. “ 비교 검정 ” 이라며 ? 그런데 왜 ‘ 우연일 확률 ’ 을 계산하지 ?

A. 먼저 “ 두 방법이 같다 ” 고 가정하고 , 그렇다면 90:40 같은 치우침이 우연으로 나올 확률을 잰다 . 그 확률이 너무 작으면 “ 같다 ” 는 가정을 접는다 = 두 방법이 다르다 . 확률을 재는 것이 곧 비교하는 방법이다 .

# BH 보정 — 60 번 검정한 결과를 어떻게 믿나

## 1 왜 보정하나 — 여러 번 하면 우연이 쌓인다

3 층화 × 4 baseline × 5 압축비 = 60 번 검정

60 개 전부 진짜 차이가 없어도  $60 \times 0.05 =$  평균 3 개가 우연히 ‘유의’로 뜬다.  
그래서 문턱을 조여야 한다.

### Tier-1 판정식

하드케이스 (alert 태그 + 본문 non-ERROR) 에서  
4 개 baseline 모두 대비  
 $p_{bh} < 0.05$  AND  $b > c$  이면 통과

※ 하드케이스는 ‘위치 (중간/앞)’ 조건이 아니라 라벨 · 레벨 기준으로 정의한다. 위치 편향 (앞쪽 솔림) 은 신호로 별도 검증됨.

2 원리 — p 값을 재료로 문턱을 조정. p 값 60 개를 줄 세워 순위별로 합격선을 조정. 통제 대상 = ‘고른 것 중 가짜 비율 (FDR)’ 을 5% 이하로. Bonferroni 보다 덜 엄격해 검정력이 높다.

“p 값을 재료로” = 채점 (McNemar) 은 끝났고, BH 는 그 점수표만 보고 합격선을 정하는 감독관. 원자료는 안 본다.

### ? 내가 부딪힌 질문

Q. 60 개 검정이 서로 얹혀 있는데, BH 를 그냥 써도 되나?

A. 60 개가 전부 LogPress 를 공유해 ‘같은 방향으로’ 얹힌다 (양의 상관). 이 경우 BH 는 오히려 더 보수적으로 작동해 이미 안전하다. 다만 그걸 완전히 증명하진 못하므로, 얹힘과 무관하게 보장되는 Holm 을 함께 돌려 방어한다.