

LogPress

고민했던 점

모델 선택 · 보존율 측정 · 베이스라인 비교 · 어텐션 설계 · 평가 단계

A

모델 선택 / 보존율 측정 방식

핵심 로그는 라인 단위라 kv 헤드 · 보존율 기준을 기존처럼 자동값에 맡길 수 없다 — 우리가 정해야 한다 .

- 모델 선택은 기존 베이스라인들은 kv 헤드수를 고민하지 않고 자동적으로 계산된 값을 사용해서 , 참고하지 않음 .
- 하지만 우리는 로그 맞춤형 압축기를 만드는것이고 , 라인 단위로 보기때문에 토큰이 살았는지 죽었는지 중요 .
- 그렇다면 kv 헤드를 어떻게 참고하는것이 좋을까 ? 다른 연구들처럼 kv 헤드를 안보는것이 맞는걸까 ?
- 기존 베이스 라인들도 효율대비 정확성을 평가했을때 어떻게 기준을 산정했는가 ? 를 안다면 보존율 측정 방식에 참고가 되지 않을까 ?

C

베이스라인과 로그프레스를 비교하는것이 맞나 ?

핵심 기존 베이스라인은 메모리용이지 로그용이 아니라 , 동등 비교가 안 된다 — 새 비교군이 필요하다 .

두개는 목적성 자체가 다르다 . 기존 베이스라인은 메모리를 줄이려고 한것이지 , 로그를 목적으로 설계한 압축기가 아니기때문에 비교군에 알맞지 않다 .

→ 다른 추가적인 비교군이나 방법을 추가하는것이 맞다 .

어텐션 설계 순환문제

핵심 어텐션을 얻으려면 로그를 먼저 넣어야 하고 , 질문까지 넣으면 결국 서술형 RCA 가 돼버린다 .

- 어텐션 값을 얻으려면 , 모델에게 먼저 로그를 던져야 한다 .
- 질문과 함께 로그를 모델에 넣는다면 사용자가 로그와 질문을 넣는것은 같은 선상에 있다고 한다면 , 그럼 서술형 rca 가 되는것이 아닌가 ?

D

평가 단계 세분화

핵심 핵심 평가를 낮추고 3 층으로 나눠, 보존율 · 정답률이 각각 못 보는 것을 단계로 메운다.
핵심 평가를 낮추고, 천천히 한다.

1 층 평가

11 월 (기말고사 기간 전)

2 층 평가

2 월 초

3 층 평가

2 월 말

보존율이 못재는것 : 살아있다와 모델이 쓴다는 다름 . 모델이 그 재료를 실제로 활용하는가 ? / rca 정답률이 못재는것 : 2 층의 바닥효과를 메운다 . 좋은 압축이든 나쁜 압축이든 모두 0 으로 낮아짐 . 정답률이 낮아도 , logpress 에는 정답이 38%, h20 는 9% 처럼 틀린 비율 차이를 살펴본다 .