

LogPress 프로젝트 회의록

정리일 2026-08-22 · 트랙 A 인프라 · B 데이터 · C 매핑/압축 · D 리드/평가 · 정리 담당 D

0. 한눈에

중간고사·3주 휴식을 고려해 **M3(2 단계, 9 주차 관문)**까지 각자 맡은 일을 마무리할 수 있게 속도를 조절한다. 이번 회의의 핵심은 **C의 LogPress 구현 방향**(토큰 ↔라인 매핑 문제)과 그에 따른 **M3 관문 경로 확인**이다.

1. A (인프라) — M3 까지 준비물 · 트랙별 정리

A는 **M3 까지 각 트랙이 무엇을 준비해야 하는지** 확인을 요청했다. 임계 경로는 0 단계 → ①킬스위치(완료·GO) → 2 단계 매핑 → ② PoC(M3) → 3 단계 LogPress → 4 단계 1 층이며, M3(9 주차)까지 트랙별 준비물은 아래와 같다.

트랙	M3(9 주차)까지 준비물
A 인프라	환경 완료(M0) 유지 · Baseline 4 종 재현 진행 · 6 주차 이후 "직접 Hook(Cache 서브클래스)" 백업경로를 C와 병렬 조사
B 데이터	Nezha 전처리 병렬 착수(3주~, 8주 확보, M-N 관문) · 킬스위치용 cause 라벨 공급 · 하드케이스(비-ERROR/위치편향) 개수 D에 공유 · 11주차 말 평가셋 D 인계
C 매핑	(M3 오너) 라인→토큰 매핑 + PoC — "마스크→전레이어 KV 삭제" 동작 입증 · 전담(겸직 금지)
D 리드	킬스위치 판정(완료·GO) · M5 평가코드 선구현 · 주 1회 Nezha 점검 · 관문 신호등 · M3 판정 준비

※ 겸직 규칙: B+C 겸직은 금지(5~11주 정면 충돌로 Nezha 붕괴). C는 전담 필수.

2. C (매핑/압축) — LogPress 구현 방향

한 줄 요약 C의 고민은 전부 **"압축의 단위 불일치"** 하나에서 나온다. KV 캐시 압축은 **토큰(단어 조각) 단위**로 작동하는데, 로그의 의미는 **라인 단위**다. 이 둘을 잇는 다리를 직접 만들겠다는 것이 C의 계획이다.

2-1. 문제의 핵심 — 토큰 단위 vs 라인 단위

모델은 문장을 **토큰**으로 쪼개고, 토큰마다 Key-Value 한 쌍을 캐시에 저장한다. KV 압축기는 그 **토큰 하나하나**에 점수를 매겨 살릴지 버릴지 정한다. 그런데 "원인 줄"은 여러 토큰에 걸쳐 있고, 심지어 **라인 ID 숫자조차 여러 토큰으로 쪼개진다** (예: 12345 → 123 + 45). 그래서 원인 "줄"을 통째로 보존하려면 세 가지가 필요하다.

단계	해야 할 일
① 매핑	어떤 토큰들이 어느 라인에 속하는지 대응표를 만든다
② 집계	그 라인에 속한 토큰들의 중요도를 하나의 "라인 점수"로 합친다
③ 라인 단위 유지	살리고/버리기를 라인 단위로 — 한 줄이면 그 줄의 토큰을 전부 함께 처리

→ **C의 첫 번째 고민** = ① 토큰↔라인 매핑을 어떻게 만들고, 매핑 후 모델에 넣었을 때 출력이 깨지지 않는지 확인.

2-2. 두 번째 고민 — 라인의 중요도를 무엇으로 재나

- 어텐션(쿼리가 각 토큰을 얼마나 주목하는지) 점수를 신호로 쓸 수 있는데, 실제로 어떤 값이 나올지 아직 미지수.

- 토큰별 점수를 **라인 하나의 점수로 합치는 방법**(최댓값/평균/합 등)을 정해야 한다.
- 이 "라인 중요도 산출"이 LogPress의 심장 — 여기서 위치·회귀도·레벨·시간 신호가 결합된다.

연결 포인트 (문서 간) 이 토큰↔라인 "무엇을 살리고 왜 버렸나"는 **고민점 정리 § 1.6(keep_mask)**와 같은 문제다. 보존율을 정확히 재려면 "살아남은 토큰이 어느 라인인지"를 되짚어야 하므로, 매핑은 구현의 전제이자 보존을 채점의 전제다.

2-3. 구현 결정 3가지

결정	내용	이유
① 직접 구현	kvpress를 그대로 쓰지 않고 LogPress를 처음부터 작성. kvpress는 참고용 패턴으로만	kvpress는 토큰 단위라, 라인 단위로 바꾸려면 너무 많이 뜯어고쳐야 함
② Qwen 프로토타입	프로토타입은 Qwen으로 구현	최종 타깃 Llama와 별개(A 파이프라인은 이미 Llama로 확정). 프로토타입은 손에 익은 Qwen으로 빠르게
③ 직접 연결	Qwen에 바로 연결 → "백업경로 조사 불필요"라고 판단	kvpress를 안 쓸 예정이므로

단, C 스스로도 **"결국 Base(Scorer)Press 로직은 건드리게 될 것"**이라고 했다. 즉 처음부터 짜더라도 사실상 같은 핵심 (**점수 → 마스크 → KV 삭제**)을 라인 단위로 다시 구현하는 셈이다.

2-4. 로드맵과 대조 — M3 관문·확인 필요 (D가 판정 소유)

C가 지금 하는 일이 **바로 M3(2단계 "라인→토큰 매핑·PoC", 5~9주차, GO/NO-GO 관문)**이다. 아래는 로드맵과 어긋나는지 D가 확인할 지점이다.

항목	로드맵(통합확정본)	C의 계획	확인 필요
M3 GO 조건	"마스크 → 전 레이어 KV 삭제 동작"	직접 구현 + Qwen 직결	C 방식이 이 GO 조건을 그대로 만족하는가?
백업경로	① kvpress 커스텀 press ② fork ③ Cache 서버클래스 — C가 A와 병렬 조사(리스크 완충)	"불필요"로 생략	직접 구현이 사실상 ③경로를 주 경로로 채택 → 주 경로가 막히면 되돌아갈 폴백이 사라짐
3단계 (M4)	"kvpress BasePress 상속, 마스크 적용 LogPress"	상속 대신 직접 작성	문서상 "상속" 전제를 "직접 작성"으로 갱신할지

D 판단 요망 (2가지) (a) C의 "직접 구현 + Qwen 직결"을 **M3 공식 경로로 승인**할지. (b) 승인 시, 백업경로를 완전히 버리지 말고 **"막히면 어디로"** 최소 폴백 한 줄이라도 남길지. 백업경로 조사 생략은 로드맵의 M3 리스크 완충을 없애는 결정이므로, 관문 소유자(D)의 확인이 필요하다.

3. D (리드/평가)

3-1. 이번 주 진행

- KPI(평가) 코드 수정을 상당 부분 완료 — **마무리만 남은 단계**.
- 설계에서 사용한 기법들이 신뢰할 수 있는지 검증하는 문서 작성 완료.
- 그동안의 고민점 문서 작성 — 우리의 목적은 무엇이고 각 평가(1층/2층)가 무엇을 요구하는가, 미래 과제로 남길 주제와 당장 해결해야 할 문제 등을 구분.
- RCA 평가 정의를 다시 문서로 작성 — RCA는 우리가 **간략한(제약형) 형태로** 하되, 대표 사례 OpenRCA(정답 원인 식별 accuracy) 등이 있고 현재 RCA 평가의 한계점도 정리. 우리는 **LLM이 얼마나 원인을 잘 맞추는가**를 평가한다. 최근 기준이 **"인과 경로·추론까지"**로 올라가는 중이며, **벤치마크 점수 ≠ 실전 RCA**.

3-2. M3까지, 그리고 M5 준비

D는 **처음과 끝이 무겁고 중반(4~10주)이 가볍다**. 이 가벼운 구간에 **M5(1층 평가) 코드를 미리 다 짜두는 것**이 액션플랜의 핵심 전략이다. 10주차에 물리면 16주

안에 못 끝낸다.

#	D가 할 일 (구체)	시점/판정
1	KPI(평가) 코드 마무리 — 보존율 채점 함수 확정	진행 중 → 마감
2	M5 평가 하네스 선구현: 보존율 곡선(압축률 50~90% × baseline 4 종), 증화(전체/비-ERROR/위치편향), BH 보정·방향 검정 (b>c)	중반(4~10 주)
3	제약형 RCA 태스크 구현: K 지선다(K=4~5)·라인지목 — RCA 평가기준.md 가 스펙	중반 → M6 대비
4	Nezha 전처리 주 1 회(15 분) 점검 [B 와] — 방치 금지(5 단계 생사 관문)	3~11 주 매주
5	3 대 관문 리스크 신호등(M1/M3/M-N) 매주 갱신 · 관문 주차엔 GO/NO-GO 회의 소집	매주
6	M3 관문 판정 준비: "마스크→전레이어 KV 삭제" 확인 절차 정의 + C 경로 승인 여부 결정	~9 주 (M3)
7	LITM 폐기 반영 전파: 1 층 증화의 "중간위치" → 실측(앞쪽 쓸림)에 맞게 재정의·용어 통일	문서 갱신

7 번은 새로 생긴 일 — 꼭 챙길 것 킬스위치 실측이 **앞쪽 쓸림**으로 나왔는데, 액션플랜의 1 층 PASS 판정식은 아직 **"non-ERROR + middle(중간위치)"** 부분집합을 쓴다. "middle"이 실측 방향과 어긋나므로, 증화 기준을 앞쪽 쓸림에 맞게 재정의할지 D 가 결정해 문서에 반영해야 한다.

4. 속도 조절 · 일정

- 중간고사 및 시험 3 주 휴식을 감안해 M3 까지 각자 분량을 마무리할 수 있게 속도 조절.
- C 목표: 1 층 평가(M5) 전까지 LogPress 완성(썬더버드 기준), 가능하면 3 주 휴식 진입 전.
- 안전판: 4 단계(1 층 평가) 완주 = 발표 가능 최소선(13 주차). 2 층(RCA delta)은 "있으면 결정타, 없으면 1 층으로 방어".

5. 액션 아이템

담당	액션	기한
C	토큰↔라인 매핑 방식 결정 + 라인 중요도 집계법(최대/평균/합) 결정	M3 진입
C	매핑 후 Qwen 출력 정상 여부 검증(작은 예제)	M3 진입
D	C 경로(직접구현+Qwen) M3 공식 승인 여부 + 최소 폴백 결정	~9 주 (M3)
D	1 층 증화 "중간위치" → 앞쪽 쓸림 재정의 문서 반영	다음 주
D	M5 평가 하네스 선구현 착수	중반 구간
A	Cache 서브클래스 백업경로 C 와 병렬 조사	6 주차~
B	Nezha 전처리 진행 + 킬스위치 라벨/하드케이스 개수 공유	상시/주간
A·B·C·D	킬스위치 판정 4 인 서명 마무리(GO 확정)	즉시

※ 본 회의록은 D 의 구두 정리를 문서화한 것이며, C 발언의 기술적 맥락은 프로젝트 문서(통합확정본 2·3 단계, RoleD 액션플랜, 고민점_정리 § 1.6)에 근거해 정리함. M3 경로·증화 재정의 등 "확인 필요"로 표시한 항목은 관문 소유자(D) 결정 후 확정.