

팀 회의록 정리

Week 5 · 진행상황 공유 — a(재현·보존율) / c(어텐션 분석) / d(검정·발표)

원문 뜻 유지 · 중복 정리 · 애매 용어는 확정 용어로 교정

a 베이스라인 재현 · 보존율 측정

현재 상태 — 보존율을 아직 못 재고 있음

- baseline 재현은 했으나 **보존율 측정은 아직**. 지금 샘플 파일이 전부 정상 로그라, 원인(이상) 라인이 섞여 있어야 "무엇이 사라졌는지"를 볼 수 있는데 그게 안 됨.
- 파일 정리를 못 해서, 어떤 라인이 제거/보존됐는지 바로 확인할 수 없는 상태.

SnapKV 동작 (공유)

- 토큰으로 쪼갬 뒤 어텐션 스코어 계산 → 점수 높아 살아남은 토큰이 어느 라인에 속하는지 확인 → 그 라인을 보존.
- 라인을 조금만 남은 것 / 다 살아남은 것 등으로 구분 중 (KEEP / PARTIAL / DROP).

할 일 · 다음

- **오류(이상)가 섞인 로그**로 필드 기반 실험을 돌려 결과 공유 — 바로 할 수 있는지 확인.
- 다음 baseline 은 PyramidKV 보다 **H2O** 를 **먼저** (c 의 설계와 연관 있어 우선). 소요 시간 미정, 1 순위로 요청.
- b 역할 진행 확인은 바빠서 아직 못 함 — 확인 필요.

c 어텐션 분석 — 라인·필드 관계 설계

설계 방향

- **로그만 입력한다** (질문은 넣지 않음). 로그 라인 간의 관계를 보는 데 초점.
- 파싱 코드에서 line_id · content · node 등 필드 기반으로 쪼개고 라인 단위로 계산.
- 한 필드가 **여러 토큰으로 쪼개진다** (예: 값 하나가 토큰 여러 개로). 그래서 토큰 간 관계보다 **라인 ↔ 필드** 관계가 중요하다고 봄.

중요도 계산 방법 (핵심 — 정확히)

Mean / token — 한 필드에 속한 토큰들의 어텐션 스코어를 모두 합한 뒤 토큰 수로 나눠 평균을 낸다. 이렇게 필드별 평균을 구하고, 라인별로 모아 라인 점수를 만든다.

가설과 검증 아이디어

- 주 가설 — 찾으려는 어텐션 값이 **유난히 크거나 작게** 나오면 성공. 그 결과를 바탕으로 보존.
- 대안 가설 — 비슷한 로그끼리 어텐션이 높게 나올 것이다. 그 관계성을 찾아 압축에 이용.
- 일정 — 9 주차 목표로, 3 주간 압축기 만들 듯 진행.

아직 정리 안 된 열린 질문

- 어텐션 계산 범위 — 같은 필드끼리 계산? 다른 필드까지 계산? (아직 미확정)
- 어텐션 스코어는 모델 내부에서 값을 벡터로 바꿔 내적으로 구함 — 방향이 일치하면 값이 커짐. (동작 이해 확인용)

d 검정 · 발표 — 경계 재정립 + KPI 직접 구현

이번 주 한 것

- 지난주 피드백 후 "경계가 헛갈린다"고 느껴 스스로 다시 재정립 (생각나는 대로 적고 LLM 에 문서 정리 요청).
- 멘토 말대로 **KPI** 는 **직접 구현**하고 경계를 세움.

McNemar — 왜 이 방법인가

- 왜 같은 것을 버리나 — 2×2 표에서 LogPress 보존율은 $(a+b)$, baseline 은 $(a+c)$. 둘을 비교하면 **겉치는 a 는 상쇄되어** 엇갈린 $b \cdot c$ 만 남는다.
- 왜 정당한가 — Dietterich: 학습 비용이 커 **알고리즘을 1 회만 실행**할 수 있을 때(LLM 재학습 자유롭지 않음·자원 이슈) 허용 가능한 검정으로 McNemar 를 지목. 채점이 O/X 이고 두 모델이 같은 문제를 푼 경우엔 McNemar 가 사실상 유일.

BH — 왜 필요한가

- 전통적 다중검정은 "가짜를 하나라도 널 확률"을 통제 → 목표값 ÷ 횟수(예: $0.05/100 = \mathbf{0.0005}$)보다 작아야 함. 이러면 진짜 유의한 것까지 버리는 약점.
- BH 는 FDR 을 사용 — "100 번 돌리면 5 번 정도는 가짜일 수 있다"는 **용통성**을 가진다.

근거: 실제 장애 포스트모템 사례 + RCA 논문의 문제 정의 부분.

예상 질문 & 답 (발표 대비)

- **Q. 보존율 차이가 우연인가?** → 같은 실력이면 $b:c$ 가 5:5 로 나와야 하는데 다르게 나오면 실력차가 있다는 뜻. 그걸 보려고 검정.
- **Q. 왜 쌍만 비교?** → 수식 전개(차이 = $(b-c)/n$)로 설명.
- **Q. 60 번 돌린 걸 왜 못 믿나?** → 유의수준 0.05 라 20 번에 1 번 꼴. 차이가 없어도 우연히 3 개쯤 유의가 뜨고, 그 안에 가짜가 섞임. BH 가 그 가짜를 5% 이하로 잡아줌. (5% = "발견이라 고른 것 중 가짜 비율")
- **Q. BH 로 충분하다며 왜 Holm 까지?** → 60 개가 다 LogPress 를 공유(양의 상관)라 BH 가 오히려 더 보수적으로 작동해 안전. 다만 양의 상관을 100% 보장은 못 하므로 Holm 으로 방어.

Q. 1 층에서 재는 게 원인 보존율인가? → 아니다. 이상 보존율(proxy)이다. 이상은 원인의 근사치 — 표본이 큰 이상 라벨로 압축기 보존율을 대규모 검증하고, 진짜 원인을 맞히는지는 2 층에서 본다. 그래서 "원인 보존율"이 아니라 이상 보존율이라 정직하게 부른다.

▶ 확인 · 결정 사항 요약

	다음 액션	내용
a	이상 로그 확보	원인(이상) 라인이 섞인 로그로 보존율 측정 → 결과 공유. 다음 baseline 은 H2O 먼저(1 순위) . b 역할 진행 확인.
c	계산 범위 확정	어텐션 계산 범위(같은 필드 vs 다른 필드) 확정 + Mean/token → 라인 점수 파이프라인 정리. 9 주차 압축기 목표.
d	발표 방어 완료	KPI 직접 구현 + 경계 재정립 완료. McNemar/BH/Holm/proxy 예상 질문 답변 정리됨.