

LogPress 회의록

스터디 · 보존율 판정식 재검토 · 역할 분담

A H2O · 보존율 판정식 문제

- H2O 작성중...
- 라이브러리들이 끝남
- 썬더버드 청크파일들을 불러와서 모델로드 시키고 라인별 매핑 -> 라인이랑 토큰, 출력

지난 스터디때 지적받은 부분을 어떻게 해소할수 있을까 생각해 봤는데

- 일단 문제가 qwen이 kvhead가 두개인데 어텐션 스코어를 다르게 매기는데
- 그부분 때문에 압축을 했을때 압축률이 많이 떨어지지 않았다

observed 이게

- 로그 라인에 토큰이 하나라도 살아남으면 그 이상은 너무 많이 살아남은것이 아닌가?
- 보존율 문제는 모델의 문제이다? qwen은 두개를 써서... 보존율이 좀더 나올수 있는게 아닐까? 이게 궁극적인 원인은 아니다.
- 앞선 판정식 자체의 문제가 있다.
- 보존율 판정부터 다시 생각해 보는게 좋을것 같다...

chunk13을 한번에 넣으면 해결되지 않을까?

- 왜?
- 어텐션 스코어가 또 다르니까?
- 살아남은 토큰이 달라지니까?
- 가능성이 있다~~ 그정도...
- 그래서 보존율 판정식을 바꿀것인가?
- 베이스라인이 비교군...이니까 압축기와 평가방식이 같아야 한다.
- 평가 방식이 뭐가?
- 로그 프레스는 어떻게 판정할건가?
- 로그 프레스에서는 단순히 모델에 넣는게 아니라 스트리밍 llm 압축 아이디어?
- 어디서부터 어디까지 변이통제?
- c와 이야기를 해봐야할듯.
- 라인별로 토큰비율로 해야한다.
- 한가지 방법? 토큰으로만 보존율을 나누는 방식?
- 이렇게 하면 보존율 왜곡이 줄어들것.
- 비율로? 그러면 왜 그렇게 설정했냐도 필요할듯
- 토큰별로는 안될듯.
- 그 라인에 토큰이 얼마나 살았는가? 비율을 정하는것이 중요하다...

C 역추적 · 순수 토큰 비율 · 협업 제안

- 다 계산을 해놓고 나온 결과 값에서 나온 캐시가 어느 라인에 있는지 보고 역추적?
- 그 방식을 쓸꺼면 애초에 라인으로 넣어서 kv캐시 측정을 하는게 맞고, 로그에 최적화된 kv캐싱을 짜는건데 무슨 추가적인 방법을 넣지 말고 오리지널로 쓰자..
- 전체 토큰수 / 살아남은 토큰수 이렇게 순수하게 보자

- 그리고 각 라인의 토큰들이 얼마나 살아남았나
- 근데 그 토큰들이 이상라인에 살아남아있으면 그걸 보고..

d: 논리적 모순이 있는거 같다... 아니면 다른 방식을 찾아주고

a와 같이 한다...? 토요일부터 같이 협업을 해보는걸로... 파서부터 같이 하는걸로..

D

설계의 모순 찾기 · 자료조사

- 설계의 모순...을 찾는 미션!
- 보존율도... 베이스라인이랑 어떻게 비교해볼지...
- 어텐션 실패할걸 대비해서 다른 방법을 찾기... 자료조사 많이 하기 논문읽기
- 평가방식을 완성하려면 어텐션 필요. c: 생각정리해서 드림
- 베이스라인부터 싹 조사 해봐야할듯
- llm 작동방식들이랑